

반복 인물 이미지 편집을 위한 유지 및 삭제 지시의 상태 갱신 제약

Explicit Preservation and Removal Constraints for State Updates in Iterative Portrait Editing

김미르, 장윤석

지도교수: 안남혁

(Namhyuk Ahn)

요약: 반복 인물 이미지 편집에서는 변경할 내용과 유지하거나 삭제할 내용을 다음 프롬프트에 정확히 반영해야 한다. 본 연구는 언어 모델이 변경 사항을 추출하고 재검토한 뒤, 명시적인 유지·삭제 지시를 확인하는 후처리 규칙을 제안한다. 유지 규칙은 해당 항목의 이전 값을 보존하고 삭제 규칙은 값을 없음으로 설정한다. 개발 자료와 별도로 구성된 검증 대화 S의 8개 대화 32턴에서 동일한 모델 응답에 네 방법을 적용하였다. 여섯 항목이 모두 정확한 턴은 기준 방법 27, 유지 규칙만 27, 삭제 규칙만 28, 두 규칙 결합 29였다. 결합 시 마지막 상태가 정확한 대화는 6개에서 7개로 증가하였고, 유지해야 할 항목을 잘못 변경한 횟수는 1건에서 0건으로 감소하였다. 개선은 한 대화의 두 턴에서 나타났다. 추가 검증 T의 대화 8개 32턴에서도 정확한 턴이 28/32에서 29/32로 증가하였으나, 변경을 항목별로 적용하는 처리를 더해도 결과는 같았다. 실제 인물 사진 2명의 이미지 평가에서 목표 충족 수는 Qwen2.5-VL-3B 기준 350/384에서 358/384로, 사후 Qwen2.5-VL-7B 평가에서는 372/384에서 374/384로 증가하였다. 다만 판단 불가 감소와 설명·점수 불일치가 포함되어 이미지 품질의 향상 여부는 판단하기 어렵다. 유지·삭제 규칙의 효과를 해당 영어 문형과 합성 대화 범위에서 확인하였다.

Abstract: Iterative portrait editing requires prompts to reflect requested changes while preserving or removing specified attributes. We implement preservation and removal rules after a language model extracts and reviews the requested changes. The rules process supported expressions and record the text that triggered each rule. We compare four methods using the same model responses on set S, eight synthetic English dialogues comprising 32 turns, finalized before inference. All six attributes were correct in 27/32 turns for the baseline, 27/32 for preservation alone, 28/32 for removal alone, and 29/32 for their combination. Correct final dialogue states increased from 6/8 to 7/8. The combination also reduced erroneous changes to previously correct attributes that should remain unchanged from one to zero. All gains occurred in two turns of one dialogue. On a further set T of eight dialogues and 32 turns, correct turns increased from 28/32 to 29/32 and correct final states from 7/8 to 8/8. Applying changes separately by attribute added no further gain. An image study with two portrait references produced 66 unique outputs for 128 conditions. The 3B evaluator scored 350/384 for the baseline and 358/384 for the combination, with six of the eight additional successes coming from previously unknown judgments. A post-hoc 7B evaluation scored 372/384 and 374/384. Both evaluators produced inconsistencies between explanations and scores, which limit conclusions about image quality. The rules reduced state errors in the tested English expressions and synthetic dialogues without additional model calls.

Keywords: Iterative portrait editing, State tracking, Preservation constraints, Removal constraints

I. 서론

반복 인물 이미지 편집에서는 속성의 추가·변경·유지·삭제와 원본 복원 요청을 편집 상태에 반영해야 한다. 예를 들어 배경은 그대로 두고 목걸이를 지우라는 요청을 전체 장면의 새 설명으로 바꾸면, 목걸이 삭제를 놓치거나 변경 대상이 아닌 배경까지 원본으로 되돌릴 수 있다. 원본 사진을 매번 편집 입력으로 사용하는 방식은 누적된 얼굴 변화를 줄이는 데 도움이 될 수 있지만, 편집 요청을 잘못 해석한 오류까지 바로잡지는 않는다. 따라서 이미지 생성에 앞서 편집 상태가 현재 요청을 정확히 반영하는지 확인해야 한다.

본 연구에서는 언어 모델이 추출하고 재검토한 변경 사항에 명시적 유지·삭제 제약을 적용하는 상태 갱신 방법을 제안한다. 유지 지시가 있는 항목은

직전 값을 보존하고, 삭제 지시가 있는 항목은 없음으로 설정한다. 동일한 모델 응답에 각 규칙을 단독 또는 결합하여 적용함으로써 유지 오류와 삭제 누락에 대한 각 규칙의 효과를 분석한다.

II. 관련 연구

ChatEdit는 대화에서 편집 상태를 추적하고 이를 이미지 편집에 사용하는 구조를 제시하였다[1]. 본 연구도 이 구성을 따르며, 상태 갱신 뒤의 유지·삭제 검사에 초점을 맞춘다. SOM-DST는 상태 갱신 동작을 예측하고 필요한 값만 생성하는 접근을 제안하였다[2]. 이러한 동작 기반 상태 갱신과 달리 본 연구는 동일한 모델 응답에 적용하는 제한 문형의 후처리 효과를 비교한다.

Self-Refine은 모델의 피드백과 수정을 반복하는 방법이다[3]. 본 연구의 기준 방법은 변경 사항 추출과 한 차례 재검토에 모델을 총 두 번 호출한다. 모든 비교 방법에 같은 두 응답을 사용해 후처리 규칙의 효과를 비교한다. 특히 유지 지시를 어기고 값을 변경하거나 삭제할 물체를 남기는 오류를 다룬다.

III. 방법

1. 편집 상태와 기준 방법

편집 상태는 재킷, 상의, 핀, 목걸이, 배경, 소품의 여섯 항목으로 구성한다. 각 항목에는 지정된 속성 값 또는 ‘원본’을 저장한다. 제거 가능한 재킷·핀·목걸이·소품에는 ‘없음’도 사용할 수 있다. ‘원본’은 최초 사진의 상태로 복원하는 동작이며, ‘없음’은 대상을 제거하는 동작이다. 초기에는 모든 항목을 ‘원본’으로 설정한다.

각 턴에서 Qwen3-4B-4bit[4]가 현재 요청의 변경 사항을 JSON으로 추출한 뒤, 요청과 첫 응답을 입력받아 재검토한다. 추출기에는 현재 요청만 제공하며, 전체 대화와 방법별 이전 상태, 정답 상태는 입력하지 않는다. 이에 따라 모든 비교 방법에 동일한 두 모델 응답을 사용할 수 있다. 각 방법은 이 응답을 자신의 이전 편집 상태에 적용하고 검증한다.

모든 방법은 허용된 값인지 검사하고, 현재 상태와 같은 변경을 생략하며, 명시적인 원본 복원 요청을 처리한다. 제안 방법은 여기에 유지·삭제 제약을 적용한다. 정답은 평가에만 사용한다. 갱신한 상태는 공통 변환 함수로 편집 프롬프트를 작성하여 원본 사진과 함께 입력한다.

2. 명시적 유지와 삭제

유지 규칙은 지원하는 항목 이름과 unchanged가 함께 있는 구절에서 해당 항목의 직전 값을 보존한다. keep만으로 유지 여부를 판단하면 keep the necklace off처럼 목걸이가 없는 상태를 요구하는 문장을 잘못 처리할 수 있다. 값 변경, 인용, 조건부 표현, 대명사, 같은 항목의 후속 언급, 지원 어휘 밖 표현에는 규칙을 적용하지 않고 모델의 추출·재검토 결과를 사용한다.

삭제 규칙은 명시적인 remove 구절에서 재킷, 핀, 목걸이, 소품의 값을 없음으로 설정한다. 상의와 배경은 삭제 대상에서 제외한다. 유지 규칙과 같은 적용 조건을 확인하고 항목, 적용 값, 근거 구절을 기록한다. 유지 규칙 다음에 삭제 규칙을 적용하며, 같은 항목이 뒤에서 다시 언급되면 앞의 유지 지시를 적용하지 않는다.

이 방법은 새 모델 학습이나 추가 추론 호출을 요구하지 않는다. 다만 제한 어휘와 문형에 의존한다. 과거 상태가 이미 틀렸다면 유지 규칙은 잘못된 값도 보존할 수 있으며, 지원하지 않는 표현의 의미 해석을 개선하지 못한다.

IV. 실험 설계

1. 비교 방법과 검증 대화

초기 개발 대화 P에서는 keep을 폭넓게 탐지하는 유지 규칙이 정확한 턴 수를 기준 30/32에서 32/32로 증가시켰다. 그러나 후속 검사에서 off나 색 변경 요청을 유지 지시로 잘못 처리하였다. 새 검증 대화 Q에서 이 규칙의 정확한 턴은 12/32였고, 적용 문형을 좁힌 유지 규칙은 기준과 같은 27/32였다. 문형을 좁혀도 마지막 상태가 정확한 대화는 6/8에서 5/8로 감소하였다. 중간 턴의 잘못된 삭제는 막았지만 다음 턴의 실제 삭제 요청을 모델이 놓쳤기 때문이다.

Q 분석 후 유지·삭제 규칙을 결합하고 검증 대화 S를 새로 구성하였다. S는 연구 보조 에이전트로 만든 영어 합성 대화 8개 32턴이다. 각 대화의 정답은 작성 시 지정한 항목별 변경을 순서대로 적용해 만들었다. 대화와 정답, 코드, 프롬프트, 모델 버전을 모두 추론 전에 확정하였다. P·Q는 개발 자료이고 S는 후속 검증 자료이므로 결과를 따로 보고한다.

변경 사항 추출에는 Qwen3-4B의 4비트 양자화 모델을 사용하였다. 생성 온도는 0, 최대 출력 길이는 260토큰으로 설정하고 공통 예시 7개를 제공하였다. 32턴에 두 번씩 총 64회 호출하였다. 기준 방법, 유지 규칙만 적용, 삭제 규칙만 적용, 두 규칙 결합을 비교한다. 결합 방식의 채택 조건은 추론 전에 설정하였다. 기준보다 정확한 턴이 높고, 마지막 상태가 정확한 대화가 줄지 않으며, 유지할 항목을 잘못 변경한 횟수가 늘지 않아야 한다. 두 단독 규칙보다 정확한 턴이 많을 때 결합의 추가 효과가 있는 것으로 판단한다.

2. 평가 단위

각 요청에 따라 상태를 한 번 갱신하는 단위를 턴으로 부른다. ‘정확한 턴’은 여섯 항목이 모두 정답과 일치하는 턴 수, ‘정확한 항목’은 총 192항목 중 정답과 일치하는 수이다. ‘최종 정답 대화’는 마지막 턴의 여섯 항목이 모두 맞는 대화 수이다. ‘유지 오류’는 직전까지 정확했고 이번에도 유지해야 하는 항목을 잘못 변경한 횟수이다. 같은 대화에 속한 턴들의 의존성을 고려해 유의성 검정 없이 건수와 비율을 비교한다.

이미지 실험은 S의 32턴, 실제 인물 사진 2명, 두 방법을 조합한 128조건이다. 원본 파일과 프롬프트가 같으면 한 번 생성한 이미지를 함께 사용해 총 66개 이미지를 생성하였다. 방법 간 비교 64쌍 중 입력이 다른 경우는 두 턴과 두 인물을 조합한 4쌍이며, 나머지 60쌍은 같은 이미지를 사용한다. 내장 이미지 생성 도구의 첫 성공 출력을 사용하였다. 이 도구는 내부 모델 버전과 시드를 공개하지 않아 동일 시드로 통제할 수 없었다. 이미지 평가는 Qwen2.5-VL-3B의 4비트 양자화 모델[5]을 사용하였다. 이미지와 목표 상태를 입력하여 여섯 항목을 성공·실패·판단 불가로 판정하였다. 평가 시 방법명과

생성 프롬프트는 제공하지 않았다. 얼굴 유사도는 InsightFace buffalo_l[6]의 코사인 유사도로 측정하였다.

원본 사진은 Pexels에 공개된 Monstera Production의 인물 사진 2장이다[7,8]. 두 인물을 각각 R01, R02로 구분하고, 512×336, 512×768 크기로 입력하였다. 그림의 의상·장신구·배경은 AI 편집 결과이며 사진 속 인물의 실제 행동이나 연구 참여를 나타내지 않는다.

3. 재현 자료

실험 코드와 대화, 정답, 모델 응답, 생성 이미지 및 평가 원문은 연구 저장소에 공개하였다[9]. 정확한 모델 버전과 실행 설정은 실험별 기록에 포함하였으며, 개발 중 재계산한 결과와 검증 결과를 구분하였다.

V. 결과

1. 구성요소별 상태 정확도

표 1. S에서 유지 규칙과 삭제 규칙의 효과

방법	정확한 턴	정확한 항목	최종 정답 대화	유지 오류
기준 방법	27/32	184/192	6/8	1
유지 규칙만	27/32	185/192	6/8	0
삭제 규칙만	28/32	186/192	6/8	1
유지·삭제 결합	29/32	187/192	7/8	0

두 규칙을 결합했을 때 정확한 턴은 기준보다 2개 많아 사전 채택 조건을 충족하였다. 유지 규칙만 적용한 경우보다 2개, 삭제 규칙만 적용한 경우보다 1개 많았다. 방법 간 차이는 S3의 3턴과 4턴에서 발생하였다. S1, S2, S4, S5, S6, S8은 네 방법 모두 4턴이 정확했고, S7은 모든 방법에서 1/4였다.

2. 유지와 삭제의 상호 보완 사례

S3의 3턴에서는 식물을 삭제하고 재킷은 유지하도록 요청하였다. 기준 방법과 유지 규칙만 적용한 방법은 식물을 남겼고, 삭제 규칙은 식물의 값을 없

음으로 바꾸었다. 이어진 4턴에서는 상의와 목걸이를 원본으로 돌리되 재킷과 연한 파란색 배경은 그대로 두도록 요청하였다. 기준 방법과 삭제 규칙만 적용한 방법은 배경도 원본으로 바꾸었다. 유지 규칙은 배경을 보존하였지만 이전 턴에서 남긴 식물까지 삭제하지는 못했다.

삭제 규칙은 식물 삭제 누락을, 유지 규칙은 배경 변경 오류를 각각 방지하였다. 두 규칙을 결합한 경우에만 두 턴의 여섯 항목이 모두 정답과 일치하였다.

3. 항목별 적용을 결합한 추가 검증

항목별 적용은 각 항목의 변경을 개별적으로 검증하여 한 항목의 오류가 다른 유효한 변경까지 취소하는 것을 방지한다. S에 대한 사후 분석에서 이를 유지·삭제 규칙과 결합한 결과, 정확한 턴 수는 32/32였다. 추가 효과의 검증에는 새로 구성한 T의 8개 대화 32턴을 사용하였다. T의 대화와 정답은 추론 전에 확정하였으며, S의 사후 분석에 사용한 코드를 수정 없이 적용하였다. 모든 비교 방법에 동일한 추출·재검토 응답 64개를 사용한 결과를 표 2에 제시하였다.

표 2. T에서 항목별 적용의 추가 효과

방법	정확한 턴	정확한 항목	최종 정답 대화	유지 오류
기준 방법	28/32	187/192	7/8	3
항목별 적용	28/32	187/192	7/8	3
유지·삭제	29/32	189/192	8/8	1
항목별 적용+유지·삭제	29/32	189/192	8/8	1

T에서도 유지·삭제 규칙은 정확한 턴 수와 최종 정답 대화 수를 각각 한 개 증가시켰으며, 차이는 T7의 마지막 턴에서 발생하였다. 항목별 적용을 추가한 결과는 유지·삭제 규칙만 사용한 결과와 같았다. 이에 따라 추가 처리 없이 유지·삭제 규칙을 사용하는 방법을 선택하였다. S의 사후 재계산 결과와 새 대화 T의 검증 결과는 구분하며, 서로 다른 개발 단계에서 구성한 S와 T의 표본 수는 합산하지 않는다.

4. 이미지 편집 결과




그림 1 R01의 S3 비교에서 식물 삭제와 배경 유지에 따른 차이



그림 2 R02의 동일한 네 조건 비교

그림 1과 2는 두 방법의 입력이 달랐던 네 쌍의 생성 이미지를 전체 영역으로 보여준다. 3턴에서 삭제 대상 식물이 기준 출력에는 남고 결합 출력에서는 사라진다. 4턴에서는 기준 출력에 식물과 원본 배경이 남아 있는 반면, 결합 출력에서는 식물이 사라지고 연한 파란 배경이 나타난다.

3B 평가 모델이 목표를 충족한 것으로 판정한 항목 수는 기준 방법 350/384, 결합 방법 358/384였다. 서로 다른 이미지·목표 조합 68개 중 3개에서는 응답 형식 오류로 평가 결과를 읽을 수 없었다. 판독하지 못한 응답을 다시 채점하지 않고 판단 불가로 집계하였다.

표 3. 3B 모델의 이미지 평가

방법	목표 충족	판단 불가	6항목 모두 충족	얼굴 코사인 평균
기준 방법	350/384	20	48/64	0.910458
유지·삭제 결합	358/384	13	50/64	0.910535

증가한 8개 성공 항목 중 6개는 판단 불가에서 성공으로 바뀌었고 실패에서 성공으로 바뀐 항목은 2개였다. R02 S3 3턴의 기준 평가가 JSON 대신 느낌을 출력하여 6항목 모두 판단 불가가 된 영향이 크다. 또 같은 턴의 결합 출력에서는 소품이 없다는 설명과 ‘소품 없음’에 대한 실패 점수가 모순되었다. 따라서 증가분 전체를 실제 편집 오류의 해소로 해석하기 어렵다.

얼굴 코사인 유사도는 기준 평균 0.910458, 결합 평균 0.910535였다. 입력이 다른 네 쌍의 평균 차이는 +0.001237이지만 두 쌍은 증가하고 두 쌍은 감소하였다. 나머지 60쌍은 같은 출력이므로 전체 평균 차이만으로 얼굴 보존의 개선 여부를 판단하기 어렵다.

평가 모델에 따른 판정 차이를 분석하기 위해 Qwen2.5-VL-7B의 4비트 양자화 모델로 전체 68개 이미지·목표 쌍을 다시 평가하였다. 재평가 전에 대상과 설정을 확정하였으며 목표 문구, 파서, 온도, 최대 토큰은 1차 평가와 같았다. 같은 계열 모델을 사용한 사후 분석이므로 두 모델의 일치만으로 판정

의 정확성을 확인할 수는 없다. 7B 평가에서 목표 충족 수는 기준 372/384, 결합 374/384였고 JSON 파싱 실패와 판단 불가는 없었다.

표 4. 7B 모델의 사후 이미지 평가

방법	목표 충족	판단 불가	6항목 모두 충족
기준 방법	372/384	0	56/64
유지·삭제 결합	374/384	0	58/64

표 5. 입력이 다른 네 쌍의 목표 충족 수

인물·대화·턴	3B 기준	3B 결합	7B 기준	7B 결합
R01 S3 3턴	5/6	5/6	6/6	6/6
R01 S3 4턴	5/6	6/6	5/6	6/6
R02 S3 3턴	0/6	5/6	6/6	6/6
R02 S3 4턴	4/6	6/6	5/6	6/6

7B에서 실패에서 성공으로 바뀐 두 항목은 R01 4턴의 소품과 R02 4턴의 배경이다. 3B의 두 항목은 R02 4턴의 소품과 배경으로, 두 평가에서 모두 실패에서 성공으로 바뀐 항목은 R02의 배경 한 항목이다. 두 평가 모델의 판정이 일치한 항목 수는 판단 불가를 포함하면 367/408, 두 모델 모두 판정한 항목만 비교하면 367/387이었다.

7B 모델에서도 설명과 점수가 일치하지 않는 경우가 있었다. 두 인물의 3턴 기준 출력에 식물이 보인다고 설명한 뒤 식물이 없다고도 설명하면서 모두 성공으로 채점하였다. R02 4턴에서도 같은 소품 설명 모순이 나타났다. 표에는 평가 모델이 반환한 점수를 그대로 집계하였다. 따라서 JSON 형식 오류의 감소와 실제 편집 정확도의 향상을 구분해야 한다.

앞선 개발 대화 P의 이미지 실험에서는 128조건에 대해 68개 이미지를 생성하였다. 목표 충족 수는 기준 354/384, 유지 규칙 355/384였고 얼굴 코사인 평균은 각각 0.914851과 0.914108이었다. 입력이 다른 네 쌍 중 인물 R01의 개발 대화 P2 두 번째 턴에서 소품 판정 하나만 판단 불가에서 성공으로 바뀌

었다. 실패에서 성공으로 바뀐 항목은 없었으며 JSON 파싱 실패 4개와 설명·점수 불일치가 있었다.

VI. 논의

유지와 삭제는 서로 다른 상태 갱신 동작을 요구한다. 유지 규칙은 직전 값을 보존하므로, 이전 턴에 남은 삭제 대상까지 제거하지는 않는다. 반대로 삭제 규칙은 명시된 대상을 제거하지만 다른 항목의 불필요한 변경을 방지하지는 않는다. S3에서 두 규칙을 결합한 경우에만 식물 삭제와 배경 유지가 모두 정확했던 결과는 이러한 차이에 따른 것이다. Q에서는 keep만으로 유지 여부를 판단하여 삭제·변경 요청을 오인하였다. 이에 따라 제안 규칙은 항목 이름과 명시적 유지·삭제 표현이 함께 있는 구절에 적용한다.

S와 T는 각각 정해진 영어 문형으로 구성된 합성 대화 8개이며 개선은 S3와 T7에 집중되었다. 변경 사항 추출에는 한 종류의 4B 모델을 사용하였고, 매 턴 현재 요청만 입력하였다.

이미지 실험은 인물 2명과 생성 도구 하나를 사용하였고, 비교 64쌍 중 60쌍이 같은 출력을 공유하였다. 두 AI 평가 모두 설명과 점수의 불일치가 있어 점수 증가를 전반적인 이미지 품질 향상으로 해석하기 어렵다. 얼굴 특징 벡터의 코사인 유사도는 입력이 다른 네 쌍 중 두 쌍에서 상승하고 두 쌍에서 하락하였다.

VII. 결론

본 연구에서는 언어 모델의 추출·재검토 결과에 명시적 유지·삭제 제약을 적용하는 상태 갱신 방법을 제안하였다. 정해진 영어 문형의 합성 대화 S에서 유지 규칙은 불필요한 배경 변경을, 삭제 규칙은 식물 삭제 누락을 방지하였다. 두 규칙의 결합으로 정확한 턴 수는 27/32에서 29/32로 증가하였다. 추가 검증 대화 T에서도 정확한 턴 수는 28/32에서 29/32로 증가하였으며, 항목별 적용을 결합한 경우와 동일한 결과를 보였다. 제안 방법은 추가 모델 호출 없이 유지 오류와 삭제 누락을 감소시켰다.

참고문헌

- [1] X. Cui et al., “ChatEdit: Towards Multi-Turn Interactive Facial Image Editing via Dialogue,” EMNLP, pp. 14567–14583, 2023.
<https://aclanthology.org/2023.emnlp-main.899/>
- [2] S. Kim et al., “Efficient Dialogue State Tracking by Selectively Overwriting Memory,” ACL, 2020.
<https://aclanthology.org/2020.acl-main.53/>
- [3] A. Madaan et al., “Self-Refine: Iterative Refinement with Self-Feedback,” 2023.
<https://arxiv.org/abs/2303.17651>
- [4] A. Yang et al., “Qwen3 Technical Report,” arXiv:2505.09388, 2025.
<https://arxiv.org/abs/2505.09388>

- [5] S. Bai et al., “Qwen2.5-VL Technical Report,” arXiv:2502.13923, 2025.
<https://arxiv.org/abs/2502.13923>

- [6] InsightFace Contributors, “Model Zoo,” InsightFace.
[https://github.com/deepinsight/insightface/tree/master/m](https://github.com/deepinsight/insightface/tree/master/model_zoo)
odel_zoo

- [7] Monstera Production, “Confident black man in studio,” Pexels, photo 6311573.
[https://www.pexels.com/photo/confident-black-man-in-](https://www.pexels.com/photo/confident-black-man-in-studio-6311573/)
studio-6311573/

- [8] Monstera Production, “Cheerful black woman in studio,” Pexels, photo 6311581.
[https://www.pexels.com/photo/cheerful-black-woman-in-](https://www.pexels.com/photo/cheerful-black-woman-in-studio-6311581/)
studio-6311581/

- [9] 김미르·장윤석, 반복 인물 이미지 편집 실험 코드 및 자료, inha-capstone repository, 2026.
<https://github.com/kimmireu0220/inha-capstone>