반복 인물 이미지 편집에서 지시 검사를 이용한 상태 갱신

State Updates Using Instruction Validation in Iterative Portrait Editing

김미르, 장윤석

지도교수: 안남혁

(Namhyuk Ahn)

요약: 초기 합성 인물 6명의 10단계 편집에서 얼굴 위치를 보정한 MAE·SSIM·LPIPS는 최종 6쌍 모두 원본 기반 재생성에 유리하였다. 원본에 적용할 현재 조건을 정리하기 위해, 변경 사항을 한 번 추출한 뒤 삭제·복원·유지 대상과 현재 실행할 지시를 검사하는 방법을 제안한다. 새 합성 영어 요청 12개에서 Qwen3-4B와 Llama-3.2-3B-Instruct의 최초 응답을 단순 적용한 전체 상태 일치율은 모두 3/12였고, 제안 방법은 모두 12/12였다. 추출·재검토와 같은 검사를 결합하면 각각 12/12와 4/12였다. 세 대화의 마지막 요청을 실제 인물 두 명에게 적용한 이미지 18장을 추가 생성하였다. 전체 요청 이력을 현재 조건으로 바꾸면 평균 프롬프트 길이는 204.00토큰에서 122.67토큰으로 39.87% 줄었다. 7B AI 평가의 목표 충족 수는 전체 이력 34/36, 검사 전 조건 24/36, 검사 후 조건 36/36이었다. 얼굴 보존 지표의 변화 방향은 측정 항목에 따라 달랐다. 상태 갱신 평가는 명시한 여섯 편집 항목과 영어 문형의 합성 대화를 대상으로 한다.

Abstract: An initial comparison on six synthetic people found that original-referenced regeneration was closer to the source than ten-step sequential editing on all six final pairs using registered MAE, SSIM, and LPIPS. To compile current editing conditions for regeneration, we propose extracting changes once and checking restoration, preservation, removal, and instruction eligibility. On twelve new synthetic English requests, applying the initial response as a schema-only JSON patch matched 3/12 full reference states for both Qwen3-4B and Llama-3.2-3B-Instruct; the proposed method matched 12/12 for both. Combining extraction, model review, and the same checks matched 12/12 and 4/12, respectively. A follow-up experiment generated eighteen images from two real-person photographs using the final requests of three dialogues. Compiling checked current conditions reduced the mean prompt length from 204.00 to 122.67 tokens, a 39.87% reduction. A post-hoc 7B AI evaluator scored 34/36 target attributes for full request histories, 24/36 for unchecked states, and 36/36 for checked states. Facial preservation metrics showed mixed directions across input forms. Primary and secondary AI evaluation errors were retained. State-update evaluation covers six specified editing attributes and supported instruction forms in AI-generated synthetic English dialogues.

Keywords: Iterative portrait editing, State updates, Instruction normalization, Instruction validation

I. 서론

반복 인물 이미지 편집에서는 속성의 추가·변경·유지·삭제와 원본 복원 요청을 편집 상태에 반영해야 한다. 예를 들어 배경을 유지하고 목걸이를 지우라는 요청을 처리할 때, 목걸이 삭제를 누락하거나 배경까지 원본으로 되돌리는 오류가 발생할 수 있다. 초기 실험에서 합성 인물 6명에게 각각 10단계 편집을 적용한 결과, 얼굴 위치를 보정한 최종 MAE·SSIM·LPIPS는 6쌍 모두 원본 기반 재생성에 유리하였다. 이 결과에 따라 원본 사진에 현재까지의 편집 조건을 적용하는 구성을 사용한다. 이때 편집 요청을 잘못 해석하면 원본 사진을 사용하더라도 잘못된 상태가 생성 단계로 전달된다. 따라서 이미지 생성에 앞서 편집 상태가 현재 요청을 정확히 반영하는지 확인해야 한다.

본 연구에서는 언어 모델이 추출한 변경 사항에 지시 검사를 적용하는 상태 갱신 방법을 제안한다. 유지할 항목의 직전 값을 보존하고 삭제와 원본 복원을 구분하며, 현재 실행할 지시와 조건부·인용 표현을 구분한다. 최초 추출만 사용하는 방법과 재검토를 추가한 방법을 같은 응답으로 비교하여 정확도와 필요한 모델 호출 횟수를 분석한다.

초기 구현은 편집 대화 전체를 언어 모델에 전달하여 최종 프롬프트를 한 번에 작성하였다. 이 과정에서 이미 취소된 재킷과 장신구 조건이 최종 프롬프트에 남는 사례가 관찰되었다. 이에 따라 프롬프트 종합을 항목별 상태 갱신과 최종 문장 작성으로 나누었다. 유지·삭제 규칙으로 저장된 조건을 확인한 뒤 이미지 생성 프롬프트를 작성한다. 이 과정에서 취소한 조건과 이전 값을 지우고 유지할 조건을 남긴다. 예를 들어 은색 목걸이 추가, 금색으로 변경, 목걸이 삭제를 차례로 요청하면 최종 조건에는 목걸이 없음만 남는다. 과거 요청 전체를 전달하는 대신 현재 상태로 정리하되, 정리 과정의 정확도와 프롬프트 길이를 함께 확인해야 한다.

상태 갱신의 정확도는 이미지 생성 전에 작성되는 편집 상태로 평가한다. 상태의 정답은 요청에 명시한 변경을 누적하여 계산할 수 있으므로 이미지 평가 모델의 판단과 분리하여 검사한다. 본 연구는 유지·삭제를 구분한 후처리를 구현하고 동일한 모델 응답으로 구성요소별 효과를 비교한다. 또한 복합 요청과 표현 변화에서 발생한 오류를 분석하여 원본 복원과 유지 지시의 적용 대상을 구분한다. 실

행 대상 검사와 최초 응답 선택의 효과를 별도의 새 요청으로 검증한다.

II. 관련 연구

ChatEdit는 대화에서 편집 상태를 추적하고 이를 이미지 편집에 사용하는 구조를 제시하였다[1]. 본 연구도 이 구성을 따르며, 상태 갱신 뒤의 유지·삭제 검사에 초점을 맞춘다. SOM-DST는 상태 갱신 동작을 예측하고 필요한 값만 생성하는 접근을 제안하였다[2]. 이러한 동작 기반 상태 갱신과 달리 본 연구는 동일한 모델 응답에 적용하는 제한 문형의 후처리 효과를 비교한다.

Self-Refine은 모델의 피드백과 수정을 반복하는 방법이다[3]. 본 연구의 기준 방법은 변경 사항 추출과 한 차례 재검토에 모델을 총 두 번 호출한다. 재검토를 사용하는 구성요소 비교에서는 같은 두 응답으로 후처리 규칙의 효과를 비교한다. 특히 유지 지시를 어기고 값을 변경하거나 삭제할 물체를 남기는 오류를 다룬다.

III. 방법

1. 편집 상태와 기준 방법

편집 상태는 현재까지의 요청을 반영하여 항목마다 저장한 편집 조건이다. 재킷·상의·핀·목걸이·배경·소품의 여섯 항목을 저장한다. 각 항목에는 지정된 속성 값 또는 ‘원본’을 저장한다. 제거 가능한 재킷·핀·목걸이·소품에는 ‘없음’도 사용할 수 있다. ‘원본’은 최초 사진의 상태로 복원하는 동작이며, ‘없음’은 대상을 제거하는 동작이다. 초기에는 모든 항목을 ‘원본’으로 설정한다.

요청을 받을 때마다 Qwen3-4B-4bit[4]가 현재 요청에서 변경할 항목과 값을 JSON 형식으로 추출한다. 같은 모델이 요청과 첫 응답을 입력받아 한 차례 재검토한다. 초기 구성요소 비교에서는 이 두 응답을 공유하며 각 방법의 이전 편집 상태에 적용한다.

모든 방법은 허용된 값인지 검사하고, 현재 상태와 같은 변경을 생략하며, 명시적인 원본 복원 요청을 처리한다. 초기 구성요소 비교에서는 여기에 유지·삭제 제약을 적용한다. 정답은 평가에만 사용한다. 갱신한 상태를 공통 변환 함수로 편집 프롬프트로 바꾸고, 원본 사진과 함께 이미지 생성 도구에 입력한다.

2. 유지·삭제 지시 검사

유지 규칙은 지원하는 항목 이름과 unchanged가 함께 있는 구절에서 해당 항목의 직전 값을 보존한다. keep만으로 유지 여부를 판단하면 keep the necklace off처럼 목걸이가 없는 상태를 요구하는 문장을 잘못 처리할 수 있다. 값 변경, 인용, 조건부 표현, 대명사, 같은 항목의 후속 언급, 지원 어휘 밖 표현은 모델의 추출·재검토 결과로 처리한다.

삭제 규칙은 명시적인 remove 구절에서 재킷, 핀, 목걸이, 소품의 값을 없음으로 설정한다. 상의와 배경은 삭제 대상에서 제외한다. 유지 규칙과 같은 적용 조건을 확인하고 항목, 적용 값, 근거 구절을 기록한다. 유지 규칙 다음에 삭제 규칙을 적용한다. 같은 항목이 뒤에서 다시 언급되면 앞의 유지 지시는 규칙 적용 대상에서 제외한다.

이 방법은 사전 학습된 모델의 응답 원문을 그대로 사용한다. 규칙의 적용 범위는 지정된 어휘와 문형으로 한정하며, 그 밖의 표현은 모델이 해석한다. 유지 규칙은 직전 값을 보존하므로 과거 상태의 오류도 다음 요청으로 이어질 수 있다.

3. 상태 갱신 절차

요청을 처리할 때는 먼저 직전 상태를 복사하고 모델 응답에서 허용된 항목과 값에 맞는 변경 사항을 선택한다. 이를 복사한 상태에 적용한 다음, 현재 요청에서 지원 문형에 해당하는 구절을 찾는다. 명시적인 유지 구절의 항목은 직전 값으로 되돌리고, 삭제 구절의 항목은 ‘없음’으로 설정한다. 따라서 유지 규칙이 참조하는 값은 모델 응답을 적용하기 전의 상태이다. 모델 응답을 적용한 뒤의 값을 참조하면 잘못 변경된 값도 보존할 수 있다. 최종 상태와 함께 적용 항목, 동작 및 근거 구절을 저장한다.

예를 들어 직전 배경이 파란색인 상태에서 배경 유지와 목걸이 삭제를 요청했다고 하자. 모델이 두 항목 모두 ‘원본’으로 추출하더라도 유지 규칙은 배경을 파란색으로, 삭제 규칙은 목걸이를 ‘없음’으로 보정한다. 규칙의 적용 조건을 충족한 구절만 보정하고 나머지는 모델이 갱신한 값을 유지한다. 이 처리에는 현재 요청과 직전 상태만 사용한다.

4. 지시 구절의 정규화와 항목별 적용

표현을 바꾼 요청을 검사하자, 복원 지시가 뒤의 유지 대상에까지 적용되는 오류가 나타났다. 이를 고치기 위해 뜻이 같은 지시를 정해진 문장 형태로 바꾸는 정규화 단계를 추가하였다. 원본 복원 구절 뒤의 leaving이나 preserving을 다음 지시로 구분하고, bring back을 restore로 바꾼다. do not change와 do not alter는 해당 대상을 그대로 두는 지시로 변환한다. 예를 들어 셔츠를 원본으로 돌리면서 재킷은 유지하라는 문장을 복원 구절과 유지 구절로 나눈다. 이로써 원본 복원 검사에 재킷까지 포함되는 오류를 막는다.

정규화는 명시한 항목과 지원 어휘를 포함하는 구절에 적용한다. 인용문과 조건문은 변환 대상에서 제외하며, 같은 항목이 뒤에서 다시 언급되면 앞선 구절로 덮어쓰지 않는다. 정규화한 구절을 검증에 사용하고 변환 전후의 문장을 함께 저장한다. 언어 모델에는 원래 요청을 입력하므로 정규화가 모델 응답에 영향을 주지 않는다.

정규화와 함께 항목별 적용을 사용하여 한 항목의 형식 오류가 다른 변경까지 취소하는 일을 방지

한다. 정규화는 각 지시가 어느 항목에 적용되는지 구분한다. 항목별 적용은 추출한 값을 하나씩 검사하여 유효한 변경을 반영한다. 두 처리의 효과는 별도 조건으로 비교한다.

5. 원본 사진을 가리키는 표현의 처리

기존 정규화에 대한 추가 검증에서 "source photo"를 포함한 복원 지시를 모델이 유지로 해석한 오류가 나타났다. 이 자료를 개발에 사용하여 원본 사진을 가리키는 복원 표현과 현재 상태를 유지하는 표현을 표준 지시로 변환하도록 확장하였다. 이후 이 확장을 개선 정규화, 앞선 구현을 기존 정규화로 구분한다.

개선 정규화는 지시 동사를 기준으로 구절을 나눈 뒤 항목 목록과 문장 전체의 형태를 확인한다. 예를 들어 "Reset the shirt to the source image appearance"를 셔츠의 원본 복원으로, "Leave the background alone"을 배경의 유지로 변환한다. "Get rid of the plant completely"는 식물 삭제로 변환한다. 변환한 구절에는 기존 정규화와 같은 상태 갱신 절차를 적용한다. 모델에는 변환 전 요청을 입력한다. 정규화 구성요소 비교의 모델 호출 수와 응답은 같다.

인식하는 항목과 문형이 모두 일치할 때 변환한다. 부정·조건·인용 표현과 지원하지 않는 대상은 변환 대상에서 제외한다. 같은 항목의 뒤 지시가 앞 지시보다 우선하며, 유지 지시는 모델 응답을 적용하기 전의 값을 참조한다. 변환 전후 문장과 적용 항목을 함께 기록한다.

6. 현재 실행할 지시의 구분

복원 표현 검증에서는 조건부 지시와 인용문을 모델이 실제 변경으로 추출하는 오류도 나타났다. 이를 처리하기 위해 현재 실행할 지시에서 제외할 범위를 기록한다. if가 포함된 조건문, do not·don't·never가 앞선 동작 구절, 캡션이나 인용문이라고 명시한 경우의 인용 범위를 검사한다. 부정 구절의 범위는 다음 동작 지시가 시작되는 곳에서 끝난다.

항목의 마지막 언급이 제외 범위 안에 있으면 모델 응답을 적용하기 전의 값을 보존한다. 같은 항목이 뒤의 직접 지시에 다시 나타나면 그 지시를 적용한다. 예를 들어 캡션 속 "Remove the pin"은 핀을 삭제하는 지시로 처리하지 않지만, 뒤에서 실제로 핀을 삭제하라고 요청하면 삭제를 적용한다. 다른 항목의 직접 변경 지시는 함께 처리한다. 보존한 항목과 제외 이유, 근거 문장을 기록한다.

7. 한 번 추출한 응답의 사용

추출·재검토 응답을 분석하자 처음에 맞게 추출한 내용을 재검토가 잘못 바꾸거나 일부 항목만 반환하는 사례가 나타났다. 이에 따라 최초 추출 응답에만 지시 검사를 적용하는 방법을 비교한다. 현재 요청을 모델에 한 번 입력하여 변경 사항을 추출하고, 지시 구절 정규화와 실행 대상 검사를 적용한 뒤 상태를 저장한다. 저장한 여섯 항목으로 이미지 편집 프롬프트를 작성한다.

이 방법은 재검토 응답을 사용하지 않으며 요청당 모델을 한 번 호출한다. 추출·재검토 방식에는 두 번이 필요하다. 지시 검사에는 모델 호출과 정답을 사용하지 않는다. 실제 실행 코드에서는 입력 상태 검사, 한 번의 추출, 상태 갱신, 편집 프롬프트 작성을 하나의 절차로 연결하였다.

IV. 실험 설계

초기 이미지 실험은 합성 인물 6명의 장신구·의상·배경을 같은 순서로 10단계 편집한 자료이다. 순차 방식은 직전 출력에 현재 요구를 적용하며, 원본 기반 방식은 최초 사진에 같은 최종 요구를 적용한다. 얼굴·표정·자세와 인물 조명은 유지하도록 요청하였다. 인물마다 원본에서 정한 320×360 얼굴 영역에서 MAE·SSIM·LPIPS[10]를 측정하였다. MAE와 LPIPS는 작을수록, SSIM은 클수록 원본에 가깝다. 위치 보정은 원본과 출력의 얼굴 영역을 NCC로 비교하여 ±64픽셀 안에서 이동을 찾고, 평활화 sigma 3 설정을 주 분석으로 사용하였다. 기존 순차 출력 60장과 원본 기반 최종 출력 6장 및 원본 6장의 해시를 대조하고 저장된 수치를 재계산하였다. 초기 비교의 대상은 입력 이미지 선택이며, 프롬프트 길이는 후속 실험에서 따로 측정하였다.

1. 비교 방법과 검증 대화

상태 갱신 개발 대화에서는 keep을 폭넓게 탐지하는 유지 규칙이 전체 상태 일치율을 기준 30/32에서 32/32로 증가시켰다. 그러나 후속 검사에서 off나 색 변경 요청을 유지 지시로 잘못 처리하였다. 후속 개발 대화에서 이 규칙의 전체 상태 일치율은 12/32였고, 적용 문형을 좁힌 유지 규칙은 기준과 같은 27/32였다. 문형을 좁혀도 최종 상태 일치율은 6/8에서 5/8로 감소하였다. 대화 중간에 잘못 삭제되는 것은 막았지만 다음 요청에서 명시한 삭제 지시를 모델이 놓쳤기 때문이다.

후속 개발 결과를 분석한 뒤 유지·삭제 규칙 비교 실험을 설계하였다. 이 실험에는 AI를 이용해 작성한 영어 합성 대화 8개, 요청 32회를 사용하였다. 각 요청의 정답 상태는 대화 작성 시 지정한 항목별 변경을 초기 상태에 순서대로 적용하여 계산하였다. 대화와 정답, 코드, 프롬프트, 모델 버전을 모두 추론 전에 확정하였다. 규칙 개발에 사용한 대화와 비교 실험에 사용한 대화의 결과는 따로 보고한다.

변경 사항 추출에는 Qwen3-4B의 4비트 양자화 모델을 사용하였다. 생성 온도는 0, 최대 출력 길이는 260토큰으로 설정하고 공통 예시 7개를 제공하였다. 요청 32개를 처리하며 각각 두 번씩, 총 64회 호출하였다. 기준 방법, 유지 규칙만 적용, 삭제 규칙만 적용, 두 규칙 결합을 비교한다. 결합 방식의 채택 조건은 추론 전에 설정하였다. 전체 상태 일치율은 기준보다 높고, 최종 상태 일치율은 기준 이상이

며, 유지 지시 위반 수는 기준 이하여야 한다. 두 단독 규칙보다 전체 상태 일치율이 높을 때 결합의 추가 효과가 있는 것으로 판단한다.

2. 평가 단위

평가 단위는 사용자의 수정 요청 한 번과 그에 따른 상태 갱신이다. 전체 상태 일치율은 처리한 요청 중 모든 항목의 값이 정답과 일치한 요청의 비율이다. 기본 실험은 여섯 항목, 복합 요청 실험은 아홉 항목을 비교한다. 항목별 일치율은 평가한 전체 항목 중 값이 정답과 일치한 비율이며, 기본 실험의 분모는 32회 요청×6항목인 192개이다. 최종 상태 일치율은 각 대화의 마지막 요청 처리 후 모든 항목이 정답과 일치한 대화의 비율이다. 유지 지시 위반 수는 직전까지 정답과 일치했고 현재 요청에서도 보존해야 하는 항목을 잘못 변경한 횟수이다. 일치율은 일치 건수/전체 평가 건수로 표기한다. 예를 들어 27/32는 요청 32회 중 27회에서 모든 항목이 일치했음을 뜻한다. 같은 대화에 속한 요청들의 의존성을 고려하여 기술통계인 건수와 비율로 결과를 비교한다.

유지·삭제 규칙의 이미지 실험은 규칙 비교 실험의 요청 32회, 실제 인물 사진 2명, 두 방법을 조합한 128개 생성 조건이다. 생성 조건은 요청 처리 단계·인물 사진·비교 방법의 조합이다. 원본 파일과 프롬프트가 같으면 한 번 생성한 이미지를 함께 사용해 총 66개 이미지를 생성하였다. 방법 간 비교 64쌍 중 입력이 다른 경우는 요청 두 개와 인물 두 명을 조합한 4쌍이며, 나머지 60쌍은 같은 이미지를 사용한다. 내장 이미지 생성 도구의 첫 성공 출력을 사용하였다. 이 도구의 내부 모델 버전과 시드는 비공개이며, 시드 설정은 도구의 기본 동작을 따랐다. 이미지 평가는 Qwen2.5-VL-3B의 4비트 양자화 모델[5]을 사용하였다. 이미지와 목표 상태를 입력하여 여섯 항목을 성공·실패·판단 불가로 판정하였다. 평가 입력은 이미지와 목표 상태로 한정하였다. 얼굴 유사도는 InsightFace buffalo_l[6]의 코사인 유사도로 측정하였다.

이미지 평가의 항목별 충족률은 성공으로 판정한 항목 수를 전체 평가 항목 수로 나눈 값이며, 전체 항목 충족률은 여섯 항목 모두 성공으로 판정한 생성 조건의 비율이다. 판단 불가는 형식 오류나 판독 문제로 성공·실패를 결정할 수 없는 항목이다. 코사인 유사도는 두 얼굴 특징 벡터의 방향이 유사한 정도이며, 표에는 생성 조건별 평균을 제시한다.

원본 사진은 Pexels에 공개된 Monstera Production의 인물 사진 2장이다[7,8]. 두 인물을 각각 R01, R02로 구분하고, 512×336, 512×768 크기로 입력하였다. 사진은 공개 이미지 자료로 사용하였으며, 그림의 의상·장신구·배경은 AI로 편집하였다.

3. 재현 자료

실험 코드와 대화, 정답, 모델 응답, 생성 이미지 및 평가 원문은 연구 저장소에 공개하였다. 정확한 모델 버전과 실행 설정은 실험별 기록에 포함하였으며, 개발 중 재계산한 결과와 검증 결과를 구분하였다.

https://github.com/kimmireu0220/inha-capstone

후처리 코드에는 별도의 자동 검사를 적용하였다. 세 가지 이전 상태에서 복원·유지 대상의 조합, 두 대상의 복원, 뒤 지시의 우선 적용, 부정·조건·인용 표현을 구성하고 기준 갱신값과 비교하였다. 구성한 963개 경우에서 정답인 변경 사항을 적용한 결과가 기준 상태와 일치하였고 입력 상태도 보존되었다. 이 코드 검사에는 직접 구성한 정답 응답을 사용했다. 대화 실험에서는 모델을 실제로 호출하여 받은 응답을 사용했다.

개선 후에는 기존 사례 963개와 새 복원·유지 조합 360개, 총 1323개를 최종 지시 검사에 적용하여 예상 상태와 입력 상태 보존을 확인하였다. 실제 실행 절차도 저장한 최초 응답으로 다시 검사하여, 한 번의 추출과 상태 갱신 및 프롬프트 작성이 실험 구현과 같은 결과를 내는지 확인하였다.

4. 포즈와 표정을 포함한 복합 요청 실험

포즈·표정 요청과 속성 변경을 함께 처리하는 경우를 검사하기 위해 별도의 합성 대화를 구성하였다. 네 가지 요청 구성마다 표정 단독·표정과 포즈·속성 지시 혼합 조건의 요청 네 개로 이루어진 대화를 작성하였다. 대화는 총 12개이며 요청은 48개이다. 표정 단독 조건은 표정만 변경하고, 표정과 포즈 조건은 몸 방향과 손동작을 추가한다. 속성 지시 혼합 조건은 재킷·배경·식물·목걸이의 변경·유지·삭제·복원도 포함한다. 같은 요청 구성의 표정 목표는 세 조건에서 같게 하였다.

복합 요청 실험은 기존 여섯 항목에 몸 방향·손동작·표정을 더한 아홉 항목을 사용한다. 어휘와 허용값을 다시 정하고, 마침표로 구분한 유지·삭제·복원 구절을 검사하는 별도 구현을 사용하였다. 앞선 규칙 비교 및 재검증 실험과 달리 상태 항목과 규칙 구현을 확장하였다. 최초 추출만 사용하는 방법, 한 차례 재검토한 방법, 재검토 뒤 구절 규칙으로 보정한 방법을 비교하였다. 최초 추출은 요청당 한 번, 나머지 두 방법은 두 번 호출한다. 규칙 보정은 재검토 응답에 적용한다.

Qwen3-4B-4bit의 온도를 0, 최대 출력을 320토큰으로 설정하고 공통 예시 두 개를 제공하였다. 전체 추론은 96회이며 방법 간 응답을 공유하였다. 코드·대화·정답·설정을 추론 전에 고정하였다. 모든 항목이 정답과 일치한 요청 수와 표정·몸 방향·손동작의 정확도를 따로 집계하였다. 조건 간에는 문장 길이와 지시 종류가 함께 달라진다. 따라서 조건별 결과는 포즈와 속성 지시를 조합한 요청에 대한 처리 정확도를 나타낸다.

생성 단계는 첫 번째 요청 구성의 첫 요청을 세 조건에서 골라 두 원본 사진에 적용한 6장으로 따로 검사하였다. 선택 기준은 텍스트 결과 집계 전에 정하였다. 추출 모델의 출력 대신 정확한 요청을 직

접 전달하고 첫 성공 이미지만 사용하였다. 표정 단독·표정과 포즈·속성 지시 혼합 조건의 시각적 목표는 각각 1개, 3개, 6개이며, Qwen2.5-VL-7B-4bit로 목표별 성공·실패·판단 불가와 설명을 받았다. 이 검사는 정확한 요청을 입력했을 때의 이미지 생성 결과를 살펴보기 위한 것이다.

5. 표현 변화와 개선 방법의 검증

새 대화 재검증에 사용한 여덟 대화의 목표를 그대로 두고 요청 32개의 표현을 바꾸었다. 기존 규칙을 수정 없이 적용하여 표현 변화에 따른 오류를 확인하였다. 이 자료를 개발에 사용한 뒤 구절 정규화 코드를 고정하고 새로운 대화 네 개, 요청 16개로 검증하였다. 앞선 실험과 같은 추출 모델·예시·온도·최대 출력 길이를 사용하고, 각각 추출·재검토 응답 64개와 32개를 저장하였다. 모든 방법에 같은 모델 응답 원문을 사용하고, 각 방법이 직전까지 저장한 상태를 이어서 갱신한다.

새 대화에서는 기준 방법, 기존 유지·삭제, 구절 정규화, 항목별 적용, 정규화와 항목별 적용의 결합을 비교한다. 구절 정규화 조건은 일괄 적용을 유지하고, 항목별 적용 조건은 기존 유지·삭제 규칙을 사용한다. 결합 조건은 두 처리를 모두 사용한다. 전체 상태·항목별·최종 상태 일치율과 기준은 맞았지만 각 방법에서 새로 틀린 요청 수를 집계한다. 개발 자료 재계산과 새 대화 검증은 따로 보고한다.

6. 같은 목표의 문장 구조 대조

세 가지 항목 구성에서 복원·유지 목표를 고정하고 네 문장 구조를 비교하였다. 표준 분리 구절, leaving 연결, preserving 연결, bring back과 부정형 유지 표현을 사용하였다. 각 대화는 초기 설정, 복원과 유지, 별도 변경 요청의 세 단계로 구성하였다. 총 대화 12개·요청 36개에 대해 기존 코드를 수정 없이 적용하고 추출·재검토 응답 72개를 새로 저장하였다. 목표 구성은 세 가지이며 문장 구조 사이의 목표는 같다. 같은 초기 설정과 후속 요청의 반복 호출은 새 목표 구성과 구분하였다.

7. 표현과 지시 순서를 바꾼 추가 검증

정규화 구현을 고정한 뒤, 기존 어휘를 새롭게 조합한 요청과 규칙이 직접 다루지 않은 표현, 앞 지시를 뒤에서 수정하는 요청을 비교하였다. 네 가지 편집 조건마다 세 표현 유형의 대화를 구성하였다. 각 대화는 초기 설정, 복원과 유지, 삭제와 유지, 별도 변경의 요청 네 개로 이루어진다. 대화 12개, 요청 48개이며 추출·재검토에 모델을 총 96회 호출하였다. 모든 방법은 같은 응답을 사용한다. 기존 다섯 방법과 함께 최초 응답만 적용하는 JSON 방식, 유효한 재검토 응답을 우선 적용하는 JSON 방식을 비교하였다.

요청과 정답은 추론 전에 확정하고 모든 결과를 집계하였다. 네 가지 편집 목표를 표현 유형별로 반복하므로 같은 초기 설정과 후속 요청이 포함된다. 서로 다른 요청 문장은 32개다. 표현을 달리한 두 번째와 세 번째 요청의 정확도를 따로 제시한다. 정답은 명시한 항목별 변경을 누적하여 계산하였다. 이 자료도 연구자가 구성한 합성 영어 대화다.

8. 두 모델에서의 새 요청 검증

개선 정규화의 구현을 고정한 뒤 새로운 대화 8개, 요청 32개로 검증하였다. 복원 표현, 변경과 복원의 혼합, 앞 지시의 수정, 부정·조건·인용의 네 유형마다 대화 두 개를 작성하였다. 문장 32개는 모두 서로 다르며 앞선 개발 자료의 문장과 겹치지 않는다. 각 대화에는 요청 네 개가 포함된다. 조건부로 나중에 수행하라고 한 지시와 인용문은 현재 상태의 변경으로 계산하지 않는다. 정답은 요청에 명시한 변경을 누적하여 계산하고 채점에만 사용하였다.

같은 요청을 Qwen3-4B와 Llama-3.2-3B-Instruct[9]의 4비트 양자화 모델에 각각 입력하였다. 두 모델은 온도 0, 최대 출력 260토큰, 같은 지시문과 예시 일곱 개를 사용하였다. 모델마다 요청 32개에 추출·재검토를 각각 한 번 수행하여 실제 호출 64회와 원문 응답을 저장하였다. 총 호출은 128회이며 모델별 결과를 따로 집계한다. 모델별로 같은 응답 기록을 사용하되 최초 응답 조건은 첫 응답만 적용한다.

기존 다섯 방법에 개선 정규화와 JSON 최초 응답·재검토 우선 방식을 더한 여덟 방법을 비교하였다. 코드·요청·정답·모델 배포 버전은 추론 전에 확정하였다. 전체 상태·항목별·최종 상태 일치율, 기준이 맞았으나 새로 틀린 요청 수, 유형별 결과를 집계하였다. 이 자료는 AI를 이용해 작성한 합성 영어 대화다.

9. 실행 대상 검사의 새 요청 검증

앞선 32개 요청을 실행 대상 검사 개발에 사용한 뒤, 겹치지 않는 새 대화 네 개, 요청 16개를 확정하였다. 첫 두 대화는 실행하지 않을 지시와 다른 항목의 직접 변경을 함께 요청한다. 나머지 두 대화는 앞선 부정·조건·인용 표현 뒤에서 같은 항목의 직접 변경을 요청한다. 이를 통해 잘못된 변경을 막으면서 뒤의 실제 변경도 적용하는지 확인한다.

두 모델과 추출·재검토 설정은 앞선 검증과 같다. 모델별 실제 호출은 32회, 전체 64회다. 기존 여덟 방법에 실행 대상 검사 결합을 추가하여 비교한다. 코드·요청·정답을 추론 전에 고정하고 결과를 모델별로 집계하였다.

10. 한 번 추출하는 방법의 새 요청 검증

32개 개발 자료에서 첫 응답만 사용한 결과와 추출·재검토 응답을 사용한 결과를 비교한 뒤, 새 대화 세 개, 요청 12개를 작성하였다. 이 문장들은 모두 서로 다르며 앞선 개발·검증 요청과 겹치지 않는다. 복원과 유지, 삭제와 부정, 조건문과 인용문, 뒤의 직접 지시를 함께 포함한다. 후처리 구현과 어휘는 수정하지 않는다.

자료와 방법을 추론 전에 고정하고 두 모델에 같은 요청을 입력하였다. 전체 비교를 위해 추출·재검토를 기록하여 모델별 24회, 전체 48회 호출하였다. 한 번 추출하는 조건의 점수는 첫 응답만으로 계산한다. 최초 응답을 단순 JSON으로 적용하는 조건과는 같은 호출 수에서 비교하고, 재검토를 사용하는 조건과는 정확도와 요청당 호출 횟수를 함께 비교한다. 호출 횟수는 알고리즘 실행에 필요한 횟수이며 처리 시간이나 금액을 측정한 값과 구분한다.

11. 누적 요청과 현재 편집 조건의 이미지 비교

한 번 추출하는 방법의 대화 세 개를 이미지 생성 단계로 연결하였다. 각 대화의 요청 네 개를 처리한 마지막 조건을 실제 인물 두 명에게 적용하였다. 입력은 시간 순서대로 나열한 전체 요청, Qwen3 최초 응답을 단순 적용한 현재 상태, 같은 응답에 지시 검사를 적용한 현재 상태의 세 종류이다. 세 대화·두 인물·세 입력 방식의 18조건을 생성 전에 고정하였다. 정답 상태는 이미지 평가에만 사용하였다. 모든 조건은 최초 사진에서 한 번 생성하였고, 조건별 첫 출력을 보존하였다. 도구의 내부 모델 버전과 시드는 비공개이다.

프롬프트 길이는 같은 보존 문구를 포함한 전체 문자열을 고정 Qwen3 토크나이저로 측정하였다. 각 대화에서 요청이 하나씩 추가될 때마다 길이를 측정해 총 12개 요청 묶음을 비교하고, 마지막 요청의 이미지 18장을 생성하였다. 토큰 수는 문자열 길이 비교에 사용하였다. 얼굴 코사인 유사도는 앞선 이미지 실험과 같은 InsightFace buffalo_l로 계산하였다. 얼굴 랜드마크를 기준으로 원본과 출력을 각각 112×112로 정렬하고 MAE·SSIM·LPIPS도 계산하였다. 이 정렬은 초기 합성 인물 실험의 고정 얼굴 영역과 다른 전처리이다. 여섯 편집 목표는 Qwen2.5-VL-3B로 한 번 평가하고 원문·형식 오류를 보존하였다. 평가 모델에는 생성 방식과 프롬프트를 제공하지 않았다. 이는 기존 텍스트 검증의 이미지 후속 실험이다.

V. 결과

1. 초기 반복 편집의 얼굴 보존 지표

순차 편집의 위치 보정 얼굴 LPIPS 평균은 1단계 0.042116, 5단계 0.173505, 10단계 0.364015였다. 합성 인물 6명의 순차 편집 10단계 최종 출력과 원본 기반 최종 출력을 같은 요구에서 비교하였다. 표 1은 얼굴 위치를 보정한 LPIPS이다.

표 1. 초기 6인물 실험의 위치 보정 얼굴 LPIPS

인물	순차 편집	원본 기반 재생성
P01	0.261778	0.170199
P02	0.260761	0.117232
P03	0.345599	0.210225
P04	0.312155	0.192125
P05	0.613747	0.577223
P06	0.390048	0.246848

위치 보정 후 MAE·SSIM·LPIPS는 모두 6/6쌍에서 원본 기반 방식에 유리하였다. 위치 보정 전에는 각 지표가 5/6쌍에서 같은 방향이었다. sigma 1과 6에서도 세 지표 모두 6/6쌍에서 같은 방향을 유지하였다. 저장된 지표와 재계산 값의 최대 절대오차는 0이었다. 지표는 얼굴 위치·색·조명과 형태의 차이를 함께 반영한다. 이 결과를 바탕으로 현재 요청을 상태로 정리하여 원본에 적용하는 방법을 구성하였다.

2. 유지 규칙과 삭제 규칙의 효과

표 2. 유지 규칙과 삭제 규칙의 비교

방법	전체 상태 일치율	항목별 일치율	최종 상태 일치율	유지 지시 위반 수
기준 방법	27/32	184/192	6/8	1
유지 규칙만	27/32	185/192	6/8	0
삭제 규칙만	28/32	186/192	6/8	1
유지·삭제 결합	29/32	187/192	7/8	0

결합 방법은 기준보다 요청 두 개, 유지 규칙만 적용한 방법보다 두 개, 삭제 규칙만 적용한 방법보다 한 개를 더 맞혀 사전 채택 조건을 충족하였다. 차이는 세 번째 대화의 세 번째와 네 번째 요청에서 발생하였다. 일곱 번째 대화에서는 모든 방법이 요청 네 개 중 한 개를 맞혔고, 나머지 여섯 대화는 모든 요청을 맞혔다.

3. 유지와 삭제의 상호 보완 사례

세 번째 대화의 세 번째 요청은 식물을 삭제하고 재킷을 유지하는 것이었다. 기준과 유지 규칙만 적용한 방법은 식물을 남겼으며, 삭제 규칙은 소품 값을 '없음'으로 바꾸었다. 네 번째 요청은 상의·목걸이를 원본으로 돌리고 재킷·연한 파란색 배경을 유지하는 것이었다. 기준과 삭제 규칙만 적용한 방법은 배경까지 원본으로 바꾸었고, 유지 규칙만 적용한 방법은 앞서 남은 식물을 보존하였다. 두 규칙을 결합한 경우에만 두 요청의 여섯 항목이 모두 정답과 일치하였다.

4. 새 대화에서의 재검증

규칙 비교 자료에 항목별 적용과 유지·삭제를 결합한 사후 재계산은 32/32였다. 추론 전에 확정한 새 대화 8개, 요청 32개에 같은 코드를 적용하여 재검증하였다. 모든 방법은 추출·재검토 응답 64개를 공유하였다(표 3).

표 3. 새 대화에서 항목별 적용의 효과

방법	전체 상태 일치율	항목별 일치율	최종 상태 일치율	유지 지시 위반 수
기준 방법	28/32	187/192	7/8	3
항목별 적용	28/32	187/192	7/8	3
유지·삭제	29/32	189/192	8/8	1
항목별 적용+유지·삭제	29/32	189/192	8/8	1

새 대화에서도 유지·삭제 규칙은 모든 항목이 정답과 일치한 요청 수와 최종 상태가 일치한 대화 수를 각각 한 건 늘렸으며, 차이는 일곱 번째 대화의 마지막 요청에서 발생하였다. 항목별 적용을 추가한 결과는 유지·삭제 규칙만 사용한 결과와 같았다.

5. 이미지 편집 결과

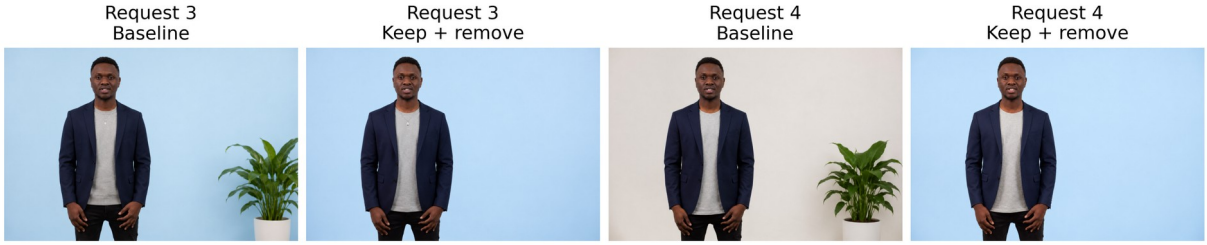


그림 1 규칙 비교 실험의 세 번째 대화에서 R01의 식물 삭제와 배경 유지



그림 2 R02의 동일한 네 조건 비교

그림 1과 2는 두 방법의 입력이 달랐던 네 쌍의 생성 이미지를 전체 영역으로 보여준다. 세 번째 요청에서 삭제 대상 식물이 기준 출력에는 남고 결합 출력에서는 사라진다. 네 번째 요청에서는 기준 출력에 식물과 원본 배경이 남아 있는 반면, 결합 출력에서는 식물이 사라지고 연한 파란 배경이 나타난다.

3B 평가 모델의 항목별 충족률은 기준 방법 350/384, 결합 방법 358/384였다. 서로 다른 이미지·목표 조합 68개 중 3개에서 응답 형식 오류가 발생하였다. 최초 평가 응답을 기준으로 집계하고 형식 오류가 있는 응답은 판단 불가로 처리하였다.

표 4. 3B 모델의 이미지 평가

방법	항목별 충족률	판단 불가 항목 수	전체 항목 충족률	얼굴 유사도 평균
기준 방법	350/384	20	48/64	0.910458
유지·삭제 결합	358/384	13	50/64	0.910535

증가한 8개 성공 항목 중 6개는 판단 불가에서 성공으로 바뀌었고 실패에서 성공으로 바뀐 항목은 2개였다. 세 번째 대화의 R02 요청 3 기준 평가가 JSON 대신 느낌표를 출력하여 6항목 모두 판단 불가가 된 영향이 크다. 또 같은 요청의 결합 출력에서는 소품이 없다는 설명과 '소품 없음'에 대한 실패 점수가 모순되었다. 즉, 성공 항목 수의 증가에는 평가 응답의 형식과 판정 오류도 영향을 주었다.

얼굴 코사인 유사도는 기준 평균 0.910458, 결합 평균 0.910535였다. 입력이 다른 네 쌍의 평균 차이는 +0.001237이지만 두 쌍은 증가하고 두 쌍은 감소하였다. 나머지 60쌍은 같은 출력을 공유하므로 전체 평균 차이는 입력이 다른 네 쌍에서 발생하였다.

평가 모델에 따른 판정 차이를 분석하기 위해 Qwen2.5-VL-7B의 4비트 양자화 모델로 전체 68개 이미지·목표 쌍을 다시 평가하였다. 재평가 전에 대상과 설정을 확정하였으며 목표 문구, 파서, 온도, 최대 토큰은 1차 평가와 같았다. 첫 평가의 오류를 확인한 뒤 같은 계열의 두 모델이 내린 판정을 비교하였다. 7B 평가에서 항목별 충족률은 기준 372/384,

결합 374/384였고 JSON 파싱 실패와 판단 불가는 각각 0개였다.

표 5. 7B 모델의 사후 이미지 평가

방법	항목별 충족률	판단 불가 항목 수	전체 항목 충족률
기준 방법	372/384	0	56/64
유지·삭제 결합	374/384	0	58/64

표 6. 입력이 다른 네 쌍의 목표 충족 수

인물·요청	3B 기준	3B 결합	7B 기준	7B 결합
R01 요청 3	5/6	5/6	6/6	6/6
R01 요청 4	5/6	6/6	5/6	6/6
R02 요청 3	0/6	5/6	6/6	6/6
R02 요청 4	4/6	6/6	5/6	6/6

7B에서 실패에서 성공으로 바뀐 두 항목은 R01 요청 4의 소품과 R02 요청 4의 배경이다. 3B의 두 항목은 R02 요청 4의 소품과 배경으로, 두 평가에서 모두 실패에서 성공으로 바뀐 항목은 R02의 배경 한 항목이다. 두 평가 모델의 판정 일치율은 판단 불가를 포함한 전체 408개 항목에서 367/408, 두 모델 모두 성공·실패를 판정한 387개 항목에서 367/387이었다.

7B 모델에서도 설명과 점수가 일치하지 않는 경우가 있었다. 두 인물의 세 번째 요청 기준 출력에 식물이 보인다고 설명한 뒤 식물이 없다고도 설명하면서 모두 성공으로 채점하였다. R02 요청 4에서도 같은 소품 설명 모순이 나타났다. 표에는 평가 모델이 반환한 점수를 그대로 집계하였다. 응답 형식 오류가 해소된 뒤에도 내용상의 모순은 남았다.

초기 개발 대화의 이미지 실험에서는 128개 생성 조건에 대해 68개 이미지를 생성하였다. 항목별 충족률은 기준 354/384, 유지 규칙 355/384였고 얼굴 유사도 평균은 각각 0.914851과 0.914108이었다. 입력이 다른 네 쌍 중 인물 R01의 두 번째 개발 대화 두 번째 요청에서 소품 판정 하나만 판단 불가에서 성공으로 바뀌었다. 실패에서 성공으로 바뀐 항목은 0개였으며 JSON 파싱 실패 4개와 설명·점수 불일치가 있었다.

6. 복합 요청에서의 삭제와 복원 혼동

표 7. 복합 요청 실험의 조건별 전체 상태 일치율

요청 조건	최초 추출	재검토	규칙 보정
표정	16/16	16/16	16/16
표정·포즈	16/16	16/16	16/16
속성 지시 혼합	4/16	4/16	16/16

표 7은 요청 처리 후 아홉 항목이 모두 정답과 일치한 비율이다. 세 방법 모두 표정·몸 방향·손동작은 조건별 48항목을 정확히 처리하였다. 혼합 조건의 항목별 일치율은 최초 추출과 재검토가 각각 124/144, 규칙 보정이 144/144였다. 최종 상태 일치율은 각각 0/4, 0/4, 4/4였다.

혼합 조건의 오류는 네 가지 요청 구성에서 같은 형태로 나타났다. 두 번째 요청의 식물 삭제와 세 번째 요청의 목걸이 삭제를 모델이 '원본'으로 추출하였고 재검토에서도 같은 값을 반환하였다. 식물 오류는 두 번째부터 네 번째 요청까지, 목걸이 오류는 세 번째와 네 번째 요청에 남아 총 20개의 항목 오류로 집계되었다. 이 20개는 두 삭제 지시의 오류가 각 요청 구성의 후속 상태에 누적된 건수이다. 사후에 삭제 규칙만 적용하여 재계산한 결과도 요청 48회 모두 정확하여, 유지·복원 규칙을 함께 적용한 결과와 같았다.

네 가지 요청 구성은 표정과 몸 방향이 다르지만 삭제·복원 문형은 공유한다. 따라서 16/16은 정해진 혼합 문형에 대한 결과이다. 포즈는 정확히 추출되었으며, 오류는 대상 삭제와 원본 복원의 혼동에서 발생하였다.

복합 요청 실험의 오류를 분석한 뒤, 포즈를 제외한 짧은 대조 요청 8개를 구성하였다. 요청을 확정하고 같은 설정으로 16회 추가 추론하여 결과를 별도로 집계하였다. 최초 추출과 재검토는 각각 7/8의 전체 상태 일치율을 보였다. 식물·목걸이의 삭제·복원을 단독으로 요청한 네 경우는 모두 맞았다. 그러나 "Remove the plant. Restore the necklace to the original."에서는 식물도 '원본'으로 추출하였다. 두 문장의 순서만 바꾼 경우는 정확하였다. 삭제와 복원만으로 구성한 짧은 요청에서도 같은 오류가 발생하였다.

7. 복합 요청 이미지의 평가 오류

정확한 요청을 직접 입력한 이미지 6장의 AI 평가에서 두 인물 모두 표정과 포즈 조건은 2/3, 속성 지시 혼합 조건은 5/6의 목표를 충족한 것으로 집계되었다. 실패 점수는 몸 방향에 부여되었으나 설명에서는 요청한 방향으로 회전했다고 서술하였다. 또한 설명이 각 목표 문장을 그대로 반복하였다. 표정 단독 조건의 두 응답은 목표 하나에 점수 세 개를 반환하고 예시 설명을 복사하였다. 평가 형식에 맞지 않는 두 응답은 모두 판단 불가로 처리하였다.

2/3과 5/6은 각 인물·조건에서 생성한 이미지 한 장에 대한 성공 판정 항목 수/전체 목표 항목 수이다. 조건별 목표 수가 다르므로 각 점수는 해당 이미지의 개별 평가 결과로 제시하였다.

8. 표현 변화와 구절 정규화의 효과

같은 편집 목표를 다른 표현으로 요청한 32개 사례에서 기준과 기존 유지·삭제 방법은 모두 25/32의 전체 상태 일치율과 5/8의 최종 상태 일치율을 보였다. 유지 지시의 동의 표현을 인식하지 못한 사례와, 원본 복원 뒤의 leaving 구절까지 복원 대상으로 포함한 사례가 나타났다. bring back 구절에서는 모델이 원본 값을 반환해도 검증 과정에서 복원 요청으로 인정하지 못하였다. 오류는 모델의 추출뿐 아니라 후처리의 지시 범위 판정에서도 발생하였다.

이 자료에 구절 정규화를 적용한 개발 결과는 29/32, 항목별 적용은 27/32, 두 처리의 결합은 32/32였다. 정규화만 사용한 경우에는 이전 상태의 오류를 유지하여 기준이 맞았던 요청 하나를 틀렸다. 항목별 적용을 결합한 경우에는 해당 오류가 발생하지 않았다. 이 재계산 결과를 바탕으로 코드를 고정한 뒤 새 대화 네 개를 검사하였다.

복잡한 후처리를 생략해도 같은 결과를 얻을 수 있는지 확인하기 위해 단순 JSON 적용 방법과 비교하였다. 항목과 값의 형식만 검사하고 요청의 어휘를 확인하는 규칙이나 유지·복원 규칙을 사용하지 않았다. 최초 응답만 적용하면 10/16, 유효한 재검토 응답을 우선 적용하면 9/16이었다. 이 비교에는 기존 실험에서 저장한 전체 응답을 사용하였다. 최초 응답 방식은 첫 응답만 사용하고, 재검토 방식과 당시 정규화 방법은 추출·재검토 응답을 모두 사용한다.

표 8. 구절 정규화와 항목별 적용의 새 대화 검증

방법	전체 상태 일치율	항목별 일치율	최종 상태 일치율	추가 오류 수
기준 방법	9/16	86/96	2/4	0
기존 유지·삭제	10/16	87/96	3/4	0
구절 정규화	16/16	96/96	4/4	0
항목별 적용	10/16	87/96	3/4	0
정규화+ 항목별 적용	16/16	96/96	4/4	0

표 8의 추가 오류 수는 기준 방법이 맞았으나 해당 방법 적용 후 틀린 요청 수다. 구절 정규화는 기준보다 요청 일곱 개, 기존 유지·삭제보다 여섯 개를 더 맞혔다. 차이는 첫째·둘째·넷째 대화에서 나타났고 셋째 대화는 모든 방법이 네 요청을 모두 맞혔다. 정규화만 사용한 결과와 항목별 적용을 결합한 결과는 같았다. 이 새 대화에서는 구절 정규화만으로 결합 방법과 같은 결과를 얻었다.

예를 들어 둘째 대화의 두 번째 요청은 셔츠와 목걸이를 원본으로 돌리되 초록 재킷과 사무실 배경은 유지하도록 지시하였다. 모델의 응답은 셔츠와 목걸이만 원본으로 지정하였다. 기존 복원 검사는 뒤의 leaving 구절까지 포함해 재킷과 배경도 원본으로 바꾸었으나, 정규화한 방법은 복원과 유지 대상을 구분하였다. 일부 후속 요청의 차이는 앞선 오류가 다음 상태에 남은 결과이다. 이 때문에 개선된 요청 수와 개선이 나타난 대화 수를 함께 집계하였다.

9. 문장 구조에 따른 처리 차이

같은 목표를 네 구조로 요청한 대조에서 전체 상태 일치율은 기준 18/36, 기존 유지·삭제 26/36, 구절 정규화 36/36이었다. 항목별 적용만 사용하면 26/36, 정규화와 결합하면 36/36으로 앞선 새 대화 검증과 같은 구성요소별 차이가 나타났다. 초기 설정은 모든 방법이 12회 모두 맞혔다. 표 9은 복원과 유지를 함께 요청한 두 번째 단계에서 세 목표 구성의 상태가 모두 맞았는지 비교한 결과다.

표 9. 같은 복원·유지 목표의 문장 구조별 전체 상태 일치율

문장 구조	기준 방법	기존 유지·삭제	구절 정규화
표준 분리 구절	2/3	3/3	3/3
leaving 연결	0/3	3/3	3/3
preserving 연결	0/3	0/3	3/3
bring back과 부정형 유지	1/3	1/3	3/3

기존 유지·삭제 규칙은 unchanged를 포함한 leaving 구절을 처리하였으나 preserving 연결에서는 세 구성 모두 틀렸다. bring back 구조에서도 세 구성 중 한 구성만 맞혔다. 정규화는 네 구조 모두에서 세 구성을 맞혔다. 다음 변경 요청을 처리한 뒤에도 결과는 표 9과 같았다. 앞서 생긴 상태 오류가 다음 요청까지 남았기 때문이다.

단순 JSON 적용을 추가로 재계산하면 최초 응답과 재검토 우선 방식이 모두 28/36이었다. 정규화는 두 단순 방식보다 여덟 요청을 더 맞혔다. 요청 문장은 서로 다른 18개이며, 같은 초기 설정과 후속 요청을 반복 호출한 응답 쌍은 모두 같았다.

10. 표현과 지시 순서에 따른 처리 결과

추가 요청 48개에서 전체 상태 일치율은 기준 24/48, 기존 유지·삭제 27/48, 구절 정규화 36/48이었다. 항목별 적용은 27/48, 정규화와 결합하면 36/48이었으며, JSON 최초 응답과 재검토 우선 방식은 모두 15/48이었다. 정규화의 항목별 일치율은 264/288, 최종 상태 일치율은 8/12였고 기준이 맞았던 요청을 새로 틀린 경우는 0개였다.

표 10는 표현을 바꾼 두 번째와 세 번째 요청만 비교한 결과다. 각 유형에는 네 편집 조건의 요청 두 개씩, 총 여덟 개가 포함된다.

표 10. 표현 유형별 복원과 삭제 요청의 전체 상태 일치율

표현 유형	기준 방법	기존 유지·삭제	구절 정규화	JSON 재검토 우선
기존 어휘의 새 조합	2/8	2/8	8/8	2/8
규칙에 없는 표현	0/8	0/8	0/8	0/8
앞 지시의 수정	6/8	8/8	8/8	0/8

기존 어휘를 새 순서로 조합한 요청에서는 정규화가 복원과 유지 대상을 구분하였다. 앞 지시를 뒤에서 수정한 요청에서는 기존 유지·삭제와 정규화가 같은 결과를 보였다. 예를 들어 배경을 원본으로 돌리라고 한 뒤 실제로는 그대로 두라고 수정하면, 마지막 유지 지시가 지정한 직전 배경을 보존하였다.

규칙에 없는 표현에서는 네 대화 모두 두 번째 요청에서 오류가 발생하였다. “Revert … to how they looked in the source photo”라는 복원 지시를 모델이 ‘유지’로 추출하였고 재검토에서도 같은 값을 반환하였다. 정규화도 이 표현을 변환하지 않아 복원

할 두 항목이 이전 값으로 남았다. 뒤의 삭제와 별도 변경을 처리한 뒤에도 두 항목의 오류가 이어졌다. 이 때문에 해당 유형의 0/8에는 최초 복원 오류 네 건과 그 오류가 남은 후속 요청 네 건이 포함된다.

11. 복원 표현 개선의 두 모델 검증

앞선 48개 요청을 개발 자료로 사용하여 재계산한 결과, 기존 정규화 36/48에서 복원 표현 개선 48/48로 증가하였다. 구현을 고정한 뒤 새로운 요청 32개를 두 모델에 각각 적용한 결과를 표 11에 제시하였다.

표 11. 복원 표현 개선의 모델별 전체 상태 일치율

방법	Qwen3-4B	Llama-3.2-3B
기준 방법	14/32	7/32
기존 유지·삭제	14/32	7/32
기존 정규화	17/32	9/32
항목별 적용	14/32	6/32
기존 정규화+항목별 적용	17/32	8/32
개선 정규화	28/32	17/32
JSON 최초 응답	16/32	7/32
JSON 재검토 우선	17/32	4/32

복원 표현을 추가한 정규화는 두 모델 모두 기준보다 정확한 요청 수를 늘렸다. Qwen3의 항목별 일치율은 187/192, 최종 상태 일치율은 6/8이었고 Llama는 각각 140/192, 3/8이었다. Qwen3에 남은 오류는 조건부 복원 지시와 캡션 속 삭제 문장을 실제 변경으로 처리한 사례였다. Llama에서는 초기 설정의 재검토 응답이 일부 항목만 반환하여 다른 조건이 누락되는 오류도 나타났다.

12. 실행 대상 검사의 효과와 재검토 오류

위 32개를 개발 자료로 사용하여 실행 대상 검사를 추가한 재계산 결과는 Qwen3 32/32, Llama 19/32였다. 새 요청 16개로 수행한 검증 결과는 표 12과 같다.

표 12. 실행 대상 검사의 새 요청 검증

방법	Qwen3-4B	Llama-3.2-3B
기준 방법	9/16	0/16
복원 표현 개선	11/16	0/16
실행 대상 검사 결합	16/16	0/16

Qwen3에서는 실행하지 않을 지시에 따른 변경을 막고 다른 항목의 직접 변경을 반영하였다. 부정·조건·인용 표현 뒤에 같은 항목의 직접 변경이 나타난 경우에도 뒤 지시를 적용하였다.

Llama는 네 대화의 초기 설정 요청에서 최초 응답의 여섯 항목을 모두 정확하게 추출하였다. 그러나 재검토에서는 목걸이 삭제 등 한두 항목만 반환하였다. 예를 들어 의상·장신구·배경·소품을 설정한 요청의 재검토 응답은 {"necklace": "none"}이었다. 이 응답을 우선 적용하면서 첫 상태부터 오류가 발생하였고 이후 요청에도 남았다. 실행 대상 검사도 누락된 초기 설정을 복원하지 못하여 전체 상태 일치율은 0/16이었다. 같은 첫 응답을 단순 JSON으로 적용한 결과는 8/16이었다.

13. 한 번 추출하는 방법의 정확도와 호출 횟수

32개 개발 자료에서 최초 응답에만 최종 지시 검사를 적용하면 Qwen3 32/32, Llama 27/32였다. 추출·재검토 응답을 함께 사용하면 각각 32/32와 19/32였다. 이를 바탕으로 코드를 고정하고 새 요청 12개에서 비교한 결과를 표 13에 제시하였다.

표 13. 새 요청에서의 전체 상태 일치율과 필요한 모델 호출 수

방법	요청당 호출 수	Qwen3-4B	Llama-3.2-3B
기준 방법	2	3/12	1/12
JSON 최초 응답	1	3/12	3/12
JSON 재검토 우선	2	3/12	1/12
추출·재검토+지시 검사	2	12/12	4/12
한 번 추출+지시 검사	1	12/12	12/12

한 번 추출한 응답에 지시 검사를 적용한 방법은 두 모델 모두 항목별 72/72, 최종 상태 3/3이었고 기준이 맞았던 요청을 새로 틀린 경우는 0개였다. 같은 첫 응답을 단순 적용한 결과가 두 모델 모두 3/12였으므로 최초 응답 선택과 함께 지시 검사의 효과도 나타났다. Qwen3에서는 재검토를 사용하는 검사 방법과 같은 결과를 보였고, Llama에서는 한 번 추출이 맞았으나 재검토 결합이 틀린 요청이 여덟 개였다. 반대 경우는 두 모델 모두 0개였다.

이 비교에서 한 번 추출하는 방법은 요청당 모델 호출 한 번으로 같은 정확도 또는 더 높은 정확도를 보였다. 재검토 응답을 사용하지 않아 정답인 최초 응답이 잘못 바뀌는 사례를 피하면서, 명시한 복원·유지·삭제 지시는 후처리로 확인하였다.

14. 현재 조건 정리에 따른 프롬프트 길이

표 14. 마지막 요청에서 전체 프롬프트의 평균 길이

입력 방식	평균 문자 수	평균 단어 수	평균 토큰 수
전체 요청 이력	958.67	156.33	204.00
검사 전 현재 조건	624.33	101.33	133.33
지시 검사 후 현재 조건	581.00	93.67	122.67

표 14는 세 대화의 마지막 요청에서 공통 보존 문구까지 포함한 전체 프롬프트 길이이다. 전체 이력의 평균 204.00토큰은 지시 검사 후 122.67토큰으로 39.87% 감소하였다. 중간 요청을 포함한 12개 묶음의 평균은 168.75토큰과 129.25토큰이었다. 첫 요청에서는 상태를 항목별로 명시한 표현이 전체 이력보다 길었고, 두 번째 요청부터는 세 대화 모두 현재 조건 표현이 짧았다. 이는 과거 요청을 현재 값

으로 대체한 효과이다. 검사 전 조건도 짧지만 잘못 추출한 값을 포함하므로 길이와 상태 정확도를 함께 비교하였다.

15. 후속 이미지의 요청 충족과 얼굴 지표

표 15. 후속 이미지의 두 AI 모델별 요청 충족 평가

입력 방식	3B 충족	판단 불가	7B 충족	판단 불가
전체 요청 이력	29/36	6	34/36	0
검사 전 현재 조건	18/36	18	24/36	2
지시 검사 후 현재 조건	30/36	6	36/36	0

각 입력 방식의 분모 36은 인물 두 명·대화 세 개의 이미지 여섯 장에서 여섯 목표를 평가한 항목 수이다. 3B 평가에서는 형식 오류 5개가 발생하였다. 형식 오류와 판단 불가는 성공에 포함하지 않고 분모에 유지하였다. 검사 전 조건의 회색 스웨터와 금색 핀을 흰 상의·핀 없음으로 설명한 응답도 있었다. 3B 평가의 오류를 관찰한 뒤 같은 18개 이미지·목표 쌍 전체를 7B 모델로 한 번 추가 평가하였다. 두 평가의 전체 점수 일치는 75/108이며, 양쪽 모두 성공·실패를 반환한 78개에서는 73/78였다. 이 7B 평가는 사후 진단이며 3B 점수와 별도로 제시하였다.

표 16. 후속 이미지의 원본 대비 얼굴 지표

입력 방식	얼굴 코사인	MAE	SSIM	LPIPS
전체 요청 이력	0.919842	0.072179	0.789038	0.095158
검사 전 현재 조건	0.901997	0.086795	0.748089	0.109213
지시 검사 후 현재 조건	0.923318	0.095572	0.754197	0.106698

모든 출력 18장에서 얼굴이 하나씩 검출되었다. 표 16의 코사인은 얼굴 특징 벡터의 유사도이며, MAE·SSIM·LPIPS는 랜드마크로 정렬한 112×112 얼굴의 평균이다. 지시 검사 후 조건은 검사 전 조건보다 얼굴 코사인·SSIM·LPIPS 평균이 유리하고 MAE 평균은 불리하였다. 전체 요청 이력과 비교하면 얼굴 코사인 평균은 높았으나 MAE·SSIM·LPIPS는 불리하였다. 따라서 프롬프트 길이 감소와 얼굴 보존 지표의 변화는 분리하여 보고한다. 조건당 첫 출력 한 장을 사용한 여섯 대응 사례의 기술통계이며, 도구의 생성 시드는 통제되지 않았다.

16. 조건부 지시와 인용문을 포함한 이미지 비교



그림 3 전체 요청 이력, 검사 전 현재 조건, 지시 검사 후 현재 조건의 생성 결과

그림 3은 실제 인물 R02에 조건부 지시와 인용문을 포함한 대화를 적용한 예이다. 왼쪽부터 전체 이력, 검사 전 조건, 검사 후 조건이다. 목표는 녹색 재킷, 원래 흰 상의, 파란 핀, 원본의 목걸이 없는 상태, 도서관과 돌 벤치이다. 검사 전 조건에는 인용문의 재킷 복원과 조건부 벤치 삭제가 남아 있었고, 검사 후에는 직접 지시만 반영하였다. 각 사진은 원본에서 따로 생성하였다. 표 15와 16의 집계는 이 예시와 나머지 두 대화를 모두 포함한다.

VI. 논의

초기 실험은 직전 출력의 재편집과 최초 원본의 재사용을 비교하였다. 그 결과에 따라 원본을 재사용하는 구성을 선택하고, 후속 실험에서는 원본에 전달할 조건을 정확하고 간결하게 정리하는 방법을 검사하였다. 마지막 요청에서 프롬프트는 평균 39.87% 짧아졌지만 얼굴 지표의 방향은 서로 달랐다. 요청 정리의 정확성과 입력 길이, 실제 출력의 얼굴 보존을 각각 측정해야 한다.

유지와 삭제는 서로 다른 상태 갱신 동작을 요구한다. 유지 규칙은 직전 값을 보존하므로 앞선 요청

의 삭제 누락도 다음 상태로 이어질 수 있다. 삭제 규칙의 보정 대상은 현재 요청에서 삭제가 명시된 항목이며, 나머지 항목은 모델의 갱신 결과를 따른다. 세 번째 대화에서는 두 규칙의 결합으로 식물 삭제와 배경 유지가 모두 정답과 일치하였다. 후속 개발 대화에서는 keep만으로 유지 여부를 판단하여 삭제·변경 요청을 오인하였다. 이에 따라 제안 규칙은 항목 이름과 명시적 유지·삭제 표현이 함께 있는 구절에 적용한다.

규칙 비교와 재검증에는 각각 정해진 영어 문형의 합성 대화 8개를 사용하였으며, 개선은 각 실험의 세 번째와 일곱 번째 대화에 집중되었다. 변경 사항 추출에는 한 종류의 4B 모델을 사용하였고, 요청마다 현재 문장만 입력하였다.

복합 요청 실험에서는 삭제를 원본 복원으로 해석한 오류가 재검토 뒤에도 남았다. 삭제 지시가 있는 항목을 '없음'으로 설정하는 규칙이 이 오류를 바로잡았다. 규칙 비교 실험에서 나타난 유지·삭제의 상호 보완과 달리 복합 요청 실험의 개선은 삭제 규칙만으로 설명된다. 복합 요청 실험은 앞선 두 실험과 어휘·예시·구현이 달라 정확도와 표본 수를 별도로 집계하였다.

앞선 유지·삭제 이미지 실험은 인물 2명과 생성 도구 하나를 사용하였고, 비교 64쌍 중 60쌍이 같은 출력을 공유하였다. 두 AI 평가 모두 설명과 점수의 불일치가 나타났다. 이미지 분석에서는 개별 편집 결과와 두 평가 모델의 판정 차이를 비교하였다. 얼굴 특징 벡터의 코사인 유사도는 입력이 다른 네 쌍 중 두 쌍에서 상승하고 두 쌍에서 하락하였다.

표현 변화 검사에서는 기존 후처리 자체가 정답인 모델 응답을 훼손하는 문제가 드러났다. 지시 구절 정규화는 이 오류를 줄였으며 새 대화 네 개에서 세 대화의 결과를 개선하였다. 개발 자료에서는 항목별 적용도 결합 효과에 기여했으나 새 대화에서는 정규화만으로 같은 결과를 얻었다. 검증에는 규칙이 처리하도록 정한 영어 어휘와 구절을 사용하였다. 새 대화 검증은 상태 기록의 정확도를 측정하였다.

문장 구조 대조에서는 목표를 같게 두고 표현만 바꾸어 차이를 확인하였다. 기존 유지·삭제 규칙의 실패는 preserving과 bring back 구조에 집중되었으며, 단순 JSON 적용도 정규화와 차이를 보였다. 동일한 추출·재검토 응답에서도 지시별 적용 대상을 구분한 후처리가 상태 오류를 줄였다. 효과를 확인한 대상은 고정한 세 가지 항목 구성과 네 문장 구조이다.

추가 검증에서는 기존 어휘를 새롭게 조합하거나 앞 지시를 수정한 문장을 처리하였지만, 새로운 복원 표현에서 발생한 추출 오류는 그대로 남았다. 따라서 지시 구절 정규화의 효과는 구현이 구분하는 동작과 표현에 달려 있다. 같은 목표의 표현 유형을 나누어 비교하면, 전체 점수만으로는 드러나지 않는 적용 범위와 후속 상태의 오류를 확인할 수 있다.

두 모델 비교에서 재검토의 결과는 사용한 모델과 고정 프롬프트에 따라 달랐다. 따라서 같은 최초 응답에 대한 단순 적용, 지시 검사, 재검토 결합을 나누어 비교하였다. 한 번 추출하는 방법의 효과는 명시한 문형의 새 요청 12개에서 확인한 결과다. 실험별 대화와 모델 응답을 보존하여 각 처리 단계가 상태에 미친 영향을 확인할 수 있도록 하였다.

VII. 결론

초기 합성 인물 6명의 10단계 편집에서 원본 기반 재생성은 얼굴 위치를 보정한 세 지표 모두 6/6쌍에서 순차 최종 출력보다 원본에 가까웠다. 이에 따라 원본에 적용할 현재 편집 조건을 정확하게 정리하는 방법을 연구하였다.

반복 인물 이미지 편집에서 변경 사항을 한 번 추출한 뒤 지시 구절을 확인하여 상태를 갱신하는 방법을 구현하였다. 원본 복원과 유지 대상을 구분하고, 현재 실행할 지시와 부정·조건·인용 표현을 구분한다. 같은 항목의 뒤 직접 지시를 적용한 후 저장한 조건으로 이미지 편집 프롬프트를 작성한다.

새 요청 12개에서 동일한 최초 응답을 단순 JSON으로 적용하면 Qwen3와 Llama 모두 3/12였고, 제안 방법은 모두 12/12였다. 재검토와 지시 검사를 함께 사용하면 각각 12/12와 4/12였다. 이 검증에서 요청당 모델 호출을 두 번에서 한 번으로 줄이면서 같은 정확도 또는 더 높은 정확도를 얻었다. 지시 검사는 지원하는 표현의 적용 오류를 바로잡았고, 최초 응답만 사용하여 재검토가 정답을 잘못 바꾸는 사례를 피하였다. 검증 범위는 AI를 이용해 구성한 영어 대화와 명시한 여섯 상태 항목 및 문형이다. 실제 인물 두 명에게 세 대화의 마지막 요청을 적용한 이미지 18장을 추가 생성하였다. 전체 이력을 현재 조건으로 바꾸면 평균 프롬프트 길이는 204.00토큰에서 122.67토큰으로 줄었다. 7B 평가의 목표 충족 수는 전체 이력 34/36, 검사 전 조건 24/36, 검사 후 조건 36/36이었다. 얼굴 지표는 비교 방식과 측정 항목에 따라 방향이 달랐으며, AI 요청 충족 평가의 오류도 함께 기록하였다.

참고문헌

[1] X. Cui et al., "ChatEdit: Towards Multi-Turn Interactive Facial Image Editing via Dialogue," EMNLP, pp. 14567–14583, 2023. https://aclanthology.org/2023.emnlp-main.899/

[2] S. Kim et al., "Efficient Dialogue State Tracking by Selectively Overwriting Memory," ACL, 2020. https://aclanthology.org/2020.acl-main.53/

[3] A. Madaan et al., "Self-Refine: Iterative Refinement with Self-Feedback," 2023. https://arxiv.org/abs/2303.17651

[4] A. Yang et al., "Qwen3 Technical Report," arXiv:2505.09388, 2025. https://arxiv.org/abs/2505.09388

[5] S. Bai et al., “Qwen2.5-VL Technical Report,” arXiv:2502.13923, 2025. https://arxiv.org/abs/2502.13923

[6] InsightFace Contributors, “Model Zoo,” InsightFace. https://github.com/deepinsight/insightface/tree/master/model_zoo

[7] Monstera Production, “Confident black man in studio,” Pexels, photo 6311573. https://www.pexels.com/photo/confident-black-man-in-studio-6311573/

[8] Monstera Production, “Cheerful black woman in studio,” Pexels, photo 6311581. https://www.pexels.com/photo/cheerful-black-woman-in-studio-6311581/

[9] Meta, “Llama 3.2 Model Card,” 2024. https://huggingface.co/meta-llama/Llama-3.2-3B-Instruct

[10] R. Zhang et al., “The Unreasonable Effectiveness of Deep Features as a Perceptual Metric,” CVPR, 2018. https://arxiv.org/abs/1801.03924