

비얼굴 순차 이미지 편집에서 얼굴 변화와 원본 기반 재생성의 탐색적 비교

An Exploratory Comparison of Facial Change and Original-Referenced Regeneration in Sequential Non-Facial Image Editing

김미르, 장윤석

()

지도교수: 안남혁

(Namhyuk Ahn)

요약: 이미지 편집 시스템에서 사용자는 옷, 배경, 액세서리를 여러 차례 수정하면서 얼굴은 유지되기를 기대한다. 그러나 앞선 생성물을 다음 입력으로 사용하는 방식에서는 요청하지 않은 얼굴 변화가 누적될 수 있다. 본 연구는 이러한 변화를 최초 원본에 누적 요구사항을 적용하는 방식과 비교하고, 원본과의 수치적 거리 및 사람이 판단하는 열화·보존의 관계를 탐색한다. 초기 실험은 합성 인물 6명과 순차 편집 7경로를 포함하며, 후속 실험은 이 중 3명의 인물에 대해 98개 출력을 생성하였다. 후속 최종 이미지 12개에는 자동 지표, 한 명의 사람 평가, 사람 결과를 제공하지 않은 별도 AI 평가를 연결하였다. 세 인물의 후속 비교에서 일괄 편집은 순차 편집보다 평균 얼굴 LPIPS가 낮았고, 사람은 일괄 결과 6개 모두와 순차 결과 6개 중 1개의 얼굴이 유지되었다고 평가하였다. 다만 AI와 사람의 열화 등급 정확 일치는 4/12에 그쳤다. 별도의 FLUX.2 Klein 4B 실험에서도 두 시드 평균 얼굴 LPIPS는 일괄 0.091313, 순차 0.124455였으나, 추가 피부 내부 영역 분석에서는 원시 MAE의 우열이 달라졌다. 따라서 원본 기반 생성은 본 조건에서 유망한 전략이지만, 원본 거리 감소를 곧바로 피부 열화 감소나 보편적인 얼굴 보존 성공으로 해석할 수 없다. 결과를 바탕으로 최초 원본과 누적 편집 상태를 분리하여 관리하는 로컬 편집기를 구현하였다.

Abstract: Sequential image editing may change facial regions even when the requested modifications concern clothing, backgrounds, or accessories. We compare feeding previous outputs into subsequent edits with regenerating from the original image and accumulated requirements. The initial study includes six synthetic identities and seven sequential trajectories. Follow-up controls produced 98 outputs from three of these identities; 12 selected final images were assessed using automatic metrics, one human pilot rater, and a separate AI session without access to human ratings. Batch editing yielded lower mean facial LPIPS for all three identities. The human rater judged facial appearance preserved in all six batch outputs and one of six sequential outputs, while exact human-AI degradation agreement was only 4/12. In a separate FLUX.2 Klein 4B comparison with two seeds, mean facial LPIPS was 0.091313 for batch editing and 0.124455 for sequential editing. Post-hoc skin-region analysis, however, reversed the ranking under raw MAE in some settings. These exploratory findings support original-referenced generation as a promising workflow under the tested conditions, while distinguishing reference distance, skin degradation, appearance preservation, and instruction fulfillment. A local editor implements this workflow by storing the original image separately from accumulated editing requirements.

Keywords: Sequential image editing, Facial preservation, Original-referenced regeneration, Perceptual similarity, Exploratory evaluation

I. 서론

사용자가 인물 사진의 셔츠를 바꾸고, 배경을 바꾸고, 핀을 추가하는 과정에서 얼굴 수정은 명시적인 목표가 아니다. 그럼에도 생성형 편집기는 얼굴의 색조, 질감, 윤곽 또는 세부를 함께 바꿀 수 있다. 이러한 비목표 영역의 변화는 요청 이행과 별도로 측정해야 한다. 편집 결과가 요구된 배경을 갖추었다더라도 얼굴이 유지되었다는 결론은 자동으로 성립하지 않는다.

다중 턴 이미지 편집과 내용 보존은 기존 연구에서도 다뤄진 문제다[1-3]. 따라서 본 연구는 누적 변화 자체를 최초로 발견하거나 새로운 생성 모델을 제안한다고 주장하지 않는다. 대신 제한된 실제 편집 과정에서 입력 전달 방식, 측정 영역, 자동 지표, 사람-AI 판정 사이에 어떤 차이가 나타나는지 확인한다. 특히 색과 위치의 변화가 포함된 원본 거리를 피부 열화의 직접 측정값으로 취급할 때 발생하는 해석 문제에 초점을 둔다.

연구 질문은 다음과 같다. 첫째, 이전 결과를 입력으로 쓰는 순차 편집과 최초 원본을 참조하는 생성은 얼굴 원본 거리에서 어떤 차이를 보이는가? 둘째, 그 차이는 편집 순서, 무변경 반복, 측정 영역 및 위치 보정에 따라 유지되는가? 셋째, 자동 지표와 AI 등급은 사람이 판단한 열화 및 보존과 어느 정도 일치하는가? 넷째, 관찰된 결과를 사용자의 연속 요청을 처리하는 시스템 설계에 어떻게 반영할 수 있는가?

본 연구의 기여는 세 가지다. 입력 정책과 후속 통제 실험을 연결한 탐색적 기록을 제시하고, 거리·열화·보존·요청 이행을 분리하여 결과를 해석하며, 피부 내부 영역에서 기존 결론에 불리한 결과까지 포함하는 민감도 분석을 제공한다. 표본 규모와 평가자의 독립성에는 제한이 있으므로 결과는 가설 형성 및 후속 실험 설계의 근거로 사용한다.

II. 관련 연구

MagicBrush는 단일 턴과 다중 턴을 포함하는 사람 주석 기반 이미지 편집 데이터셋을 제시한다[1]. 이는 편집 성능을 한 번의 결과만으로 평가하기 어렵다는 배경을 제공한다. Multi-turn Consistent Image Editing은 다중 턴에서의 누적 오차와 내용 일관성을 모델 수준에서 다룬다[2]. 본 연구는 이러한 생성 알고리즘을 직접 재현하거나 경쟁 평가하지 않고, 사용 가능한 생성기의 입력을 구성하는 정책을 비교한다.

GIE-Bench는 지시 이행과 보존 평가를 구분하며[4], EdiVal-Agent는 지시 이행, 내용 일관성, 시각 품질을

다차원으로 평가한다[3]. 본 연구에서도 얼굴 열화 등급과 얼굴 유지 여부를 별도 항목으로 유지한다. 요청한 편집의 달성 여부 역시 원본 거리로 대체하지 않는다.

SSIM은 구조적 유사도를, LPIPS는 학습된 특징 공간의 지각적 거리를 측정한다[5,6]. 두 지표 모두 본 연구에서 원본과 출력의 차이를 정량화하는 데 유용하지만, 측정값 자체가 특정 피부 결함의 진단이나 동일인 보존 판정은 아니다. MAE는 색 이동과 기하학적 어긋남에도 반응한다. 이에 따라 얼굴 사각형뿐 아니라 피부 내부 영역, 위치 보정, 평균 색 제거 분석을 함께 사용한다.

III. 연구 설계

1. 자료 범위와 분석 단위

인물 P01-P06은 합성 이미지다. 초기 순차 편집은 6명에 대해 7경로를 구성하며 P03에 두 경로가 있다. 정책 비교 기록에는 20경로와 확인된 198단계 출력이 있지만, 일부 경로가 동일한 출력을 공유하므로 이를 198개의 독립 관측으로 취급하지 않는다. 완료된 10단계 경로는 19개다. 확장 계획의 신규 27회 중 25회가 성공했고, P05의 1회 개입 경로 9단계는 도구 차단, 10단계는 미실행으로 기록했다. 실패를 임의의 품질 점수로 대체하지 않았다. 단계별 자동 분석과 최종 사람 평가의 범위도 서로 다르다.

표 1. 실험과 평가 범위

실험 묶음	생성·분석 범위	사람·AI 평가 범위
초기 10단계 및 정책 비교	6인물, 순차 7경로; 수치 분석 고유 113개	AI 고유 111개·두 세션; 사람 최종 고유 16개
후속 편집 통제	기존 3인물, 예비 14개와 추가 84개, 총 98개	선정 최종 12개에 사람 1명과 별도 AI 1세션
로컬 FLUX 정책 비교	P04, 2시드, 새 출력 8개·최종 4개	자동 지표; 독립 사람·AI 등급 없음
로컬 ROI 민감도 분석	위 8개 재분석, 최종 4개 별도 집계	새로운 생성이나 평가자 없음

초기 수치 분석 113개 중 두 개는 개입 전 후보이며 AI 평가 111개에 포함되지 않는다. 후속 12개는 98개의 부분집합이다. 원본 대 원본 대조, 재평가 문항, 개발용 생성 이미지는 독립 연구 표본으로 더하지 않는다. 초기 생성기는 도구 기반 이미지 생성 시스템이며 정확한 백엔드 모델 버전과 시드는 확보되지 않았다. 따라서 이 부분의 재현성은 보존된 입력·출력·프롬프트·분석 기록에 한정된다.

2. 입력 정책과 편집 과제

초기 10단계 과제는 귀걸이, 목걸이, 핀, 의상, 배경 등의 비얼굴 편집 및 후속 색·형태 변경으로 구성된다. 순차 정책은 직전 출력을 다음 입력으로 사용한다. 원본 기반 정책은 최초 입력에 해당 시점까지의 요구사

항을 적용한다. 중간 1회 개입, 3단계마다 개입, 알람 기반 개입, 마지막 단계만 재생성하는 변형도 기록하였다. 공유 출력이 있는 정책 비교는 독립 반복 실험이 아니라 경로와 호출 비용의 비교로 해석한다.

후속 실험에서는 셔츠, 배경, 핀의 최종 요구를 한 번에 적용하는 일괄 방식과 세 단계로 적용하는 순차 방식을 비교하였다. 최종 요구는 같지만 호출 수는 다르다. 따라서 이는 동일 계산 예산에서의 모델 성능 비교가 아니라 동일 최종 요구를 달성하는 작업 흐름의 비교다. 일괄 최종 생성 결과만으로 연속 상호작용의 모든 중간 상태까지 검증했다고 주장하지 않는다.

98개 후속 출력은 예비 분해 실험 14개, 편집 순서 실험 38개, P05-P06 재현 16개, 색·재질 요인 실험 24개, 무변경 반복 연장 6개로 구성된다. 순서 실험은 세 편

집의 여섯 순열을 포함한다. 무변경 반복은 요청 내용이 추가되지 않아도 생성 반복 자체가 변화를 유발하는지 확인하는 대조다.

3. 자동 지표와 영역

RGB를 [0,1] 범위로 정규화하여 원본과 출력 사이의 MAE를 계산한다. 얼굴 영역의 SSIM과 LPIPS(AlexNet, version 0.1)를 함께 보고하며 MAE·LPIPS는 낮을수록, SSIM은 높을수록 원본에 가깝다. 세 지표를 하나의 점수로 합치거나 열화 임계값을 사후 최적화하지 않는다. 얼굴 사각형에는 피부 외에 눈·머리카락 및 주변 내용이 포함될 수 있으므로 피부 내부 영역 분석을 별도로 수행한다.

위치 민감도 분석은 정규화 상호상관(NCC)을 이용한 정수 픽셀 평행이동으로 수행한다. 고해상도 후속 분석의 Gaussian sigma는 1, 3, 6이며 로컬 절반 해상도에서는 0.5, 1.5, 3을 사용한다. 영상 자체를 워핑하지 않고 대응 위치를 잘라 비교한다. 이 보정은 평행이동에만 대응하며 회전, 표정, 크기 또는 형태 변형을 제거하지 못한다.

피부 영역에는 원시 RGB MAE, SSIM, 고주파 성분 MAE 및 평균 RGB 제거 후 잔차 MAE를 사용한다. 픽셀 차이 d 의 평균을 μ 라 할 때 MSE는 $\text{mean}(d^2) = \mu^2 + \text{mean}((d-\mu)^2)$ 로 분해된다. 채널별 계산 후 평균하며, 이 항등식은 수치적으로 검산한다. 평균 색 성분은 통계적 분해 항이지 조명의 인과적 기여율이 아니다. MAE에는 같은 가법 분해를 적용하지 않는다.

4. 사람 평가와 AI 평가

얼굴 열화 항목은 인위적인 피부 무늬·형태 왜곡을 대상으로 하며 원래의 주름·점과 조명·색조·배치 변화는 구별한다. 등급은 없음(0), 약함(1), 뚜렷함(2), 심함(3)의 순서 척도로 평가하고, 얼굴 보존은 미유지(0), 부분 유지(1), 유지(2)로 구분한다. 초기 최종 이미지 16개와 후속 12개는 한 명의 예비 평가에 근거한다. 후속 평가자는 연구 결과와 가설에 노출되었으며, 두 열화 응답을 다시 확인한 뒤 각각 0에서 1로 변경하였다. 최초 응답과 재평가 기록은 보존하였고 본문은 재평가 반영 값을 사용한다. 재평가를 독립 관측으로 취급하지 않는다.

초기 AI 평가는 같은 기반 모델의 두 세션이 고유 111개 출력을 평가한 것이다. 세션별 원본 대조 10개와 숨은 반복 12개를 추가하였다. 후속 AI는 사람 결과·지표·방법명을 제공하지 않은 별도 세션에서 12개 후보와 원본 대조 3개를 평가하였다. 비교판 표시 문제로 처음 판정하지 못한 두 이미지는 개별 PNG 확인 후 평가하였으며 최초 기록을 남겼다. 이는 새로운 모델 간 검증이나 독립된 두 번째 사람 평가가 아니다.

5. 로컬 모델과 재현성

로컬 비교는 FLUX.2 Klein 4B의 4비트 양자화 가중치와 MFLUX 0.19.1을 사용하였다[7,8]. 실행 환경은 Apple M1, 메모리 16 GB이며, 추론은 4스텝으로 설정하였다. P04 원본을 두 방법 모두 동일하게 512×768로 축소하고 시드 42와 314를 사용하였다. 각 순차 경로에서는 같은 시드를 유지하고, 반복 간 방법 실행 순서를 반대로 하였다. 결과 품질을 이유로 재시도하거나 좋은 결과만 선택하지 않았다.

후속 분석은 저장된 출력 해시, 입력 연결, ROI 및 지표 재계산으로 검증하였다. 새 로컬 민감도 분석은 고정 얼굴 결과를 본 이후 설계한 사후 분석이다. 모든 설정을 함께 보고하여 유리한 보정 설정만 선택하지 않았다. 소수 인물·시드와 종속 관측의 한계 때문에 모집단 유의확률이나 일반화 신뢰구간을 제시하지 않는다.

IV. 결과

1. 초기 순차 경로와 원본 기반 정책

초기 순차 최종 7개를 사람은 모두 열화 3과 보존 0으로 평가하였다. 원본 기반 최종 6개는 열화 0 또는 1, 보존 2였다. 완료된 1회 개입 최종 2개는 보존 0이었고, 3단계마다 개입한 최종 1개는 보존 1이었다. 이는 중간 한 번의 개선만으로 이후 결과를 보장할 수 없음을 보여주지만, 정책별 표본 수가 다르므로 모집단 성공률로 해석할 수 없다.

P04의 10단계 경로 평균 LPIPS와 논리적 생성 호출 수를 표 2에 정리하였다. 호출 수는 실제 경과 시간이나 과금량과 동일하지 않다. 알람 방식은 원본 기반 방식과 확인된 출력 8개를 공유한다. 해당 알람은 탐색적 규칙이며 검증된 자동 감지기로 제안하지 않는다.

표 2. P04 정책별 호출·LPIPS

정책	호출	고정	보정
순차	10	0.250733	0.145487
중간 1회 개입	11	0.334774	0.150213
3단계마다 개입	13	0.178503	0.115825
알람 기반 개입	18	0.106101	0.092580
마지막만 재 생성	11	0.224328	0.133484
매 단계 원본 기반	10	0.104210	0.090963

일곱 대응 최종 비교에서 고정 영역 지표는 각 지표별 6/7이 원본 기반에 유리했고 위치 보정 후에는 7/7

이었다. P01의 고정 LPIPS는 순차 0.270484, 원본 기반 0.276156으로 반대 사례였다. 따라서 초기 자료만으로 모든 출력·모든 측정 설정에서 일괄적인 우월성을 주장할 수 없다.

2. 후속 통제 실험

세 인물의 후속 비교에서 일괄 방식의 평균 얼굴 LPIPS가 순차 방식보다 낮았다. 아래 P04 값은 편집




그림 1. 동일 최종 요구에서의 얼굴 LPIPS 비교. 초기 생성기 세 인물과 로컬 모델 두 시드는 서로 다른 실험이며 수치를 합산하지 않는다.

순서 실험에서는 지표와 반복을 가로지르는 하나의 보편적 최적 순서를 찾지 못하였다. 색·재질 요인 실험 역시 내용의 복잡도가 증가할수록 변화가 단조롭게 증가한다는 관계를 지지하지 않았다. P06의 원래 재질 조건에서도 요청하지 않은 흰 줄무늬가 생성된 사례가 있어, 비목표 얼굴 보존과 편집 요구의 정확한 이행을 별도 검사할 필요가 있다.

무변경 반복 두 경로의 평균 얼굴 LPIPS는 1단계 0.020250에서 3단계 0.062738, 6단계 0.106249로 증가하였다. 고정 MAE와 LPIPS는 각 경로에서 단조 증가했지만 모든 지표에 대해 단조성을 주장하지 않는다. 이는 명시적인 추가 편집 없이도 반복 생성이 원본과의 차이를 누적시킬 수 있음을 보여준다.

피부 분석은 얼굴 전체 수치의 해석을 제한한다. P04 단일 배경 편집의 피부 MAE는 0.049207로 셔츠 0.015323과 핀 0.014845보다 컸다. 그러나 배경 조건에서 피부 MSE의 87.8%는 평균 RGB 차이 성분이었으며, 평균 색 제거 후 MAE는 배경 0.014057, 셔츠 0.013909로 가까워졌다. 이 결과는 큰 원시 오차가 모두 피부 세부에 해당하지 않음을 시사한다.

3. 사람과 AI의 일치 및 지표 관계

후속 12개 이미지에서 일괄 결과의 사람 열화 등급은 0이 2개, 1이 4개였고, 순차 결과는 1이 4개, 2가 2개였다. 얼굴 보존은 일괄 6/6, 순차 1/6이 유지였다. 인물·반복으로 대응한 여섯 쌍에서 일괄의 열화 등급이 더

순서 실험의 일괄 및 셔츠→배경→핀 경로 비교이며, 별도 예비 분해 실험의 값과 혼합하지 않았다.

표 3. 인물별 평균 얼굴 LPIPS

인물	일괄	순차	반복
P04	0.076800	0.118081	2
P05	0.104716	0.149267	2
P06	0.119000	0.166047	2

낮은 쌍은 4개, 같은 쌍은 2개였다. 보존에서는 일괄이 더 높은 쌍이 5개, 같은 쌍이 1개였다.

표 4. 후속 사람·AI 평가

평가 항목	일괄 6개	순차 6개
사람 열화	없음 2, 약함 4	약함 4, 뚜렷함 2
사람 보존	유지 6	유지 1, 미유지 5
AI 열화	약함 6	뚜렷함 2, 심함 4

후속 AI와 사람의 열화 등급은 정확히 4/12, 한 등급 이내에서 10/12 일치했으며 Spearman 순위 상관은 0.639였다. 원본 대조 3개는 모두 AI 등급 0이었다. 방법 간 방향에는 일치가 있지만 절대 등급에는 차이가 있으므로 AI를 사람 평가의 대체물로 결론 내릴 수 없다.

초기 AI 두 세션은 고유 111개에서 99/111(89.19%) 정확 일치, 등급 2 이상 이진 기준에서 107/111(96.40%) 일치를 보였으며 선형 가중 κ 는 0.897이었다. 숨은 반복 정확 일치는 각각 11/12와 12/12, 원본 대조는 각각 10/10이었다. 이는 같은 기반 모델의 세션 일관성에 관한 결과이며 사람 간 신뢰도나 모델 다양성의 증거가 아니다.

후속 사람 열화와 얼굴 MAE, SSIM, LPIPS의 순위 상관은 각각 -0.125, -0.334, 0.502였다. 보존과의 상관은 -0.416, 0.661, -0.710이었다. 특히 MAE와 열화 사이의 약한 반대 방향 관계는 수치 거리를 열화 척도로

단순 치환하기 어렵다는 점을 보여준다. 이 상관들은 3 인물의 종속된 12개 출력과 한 사람에 대한 기술 통계다.

4. 로컬 FLUX 비교

로컬 모델의 두 시드에서 고정 얼굴 MAE·SSIM·LPIPS는 모두 일괄 방식에 유리하였다. 최종 요구는 남색 셔츠, 연한 파란 배경, 화면 기준 오른쪽의 은색 핀 하나였다. 실행자 관찰에서는 네 결과가 주요 요구를 갖추었으나 이는 독립적인 요청 이행 평가가 아니다.

표 5. 로컬 최종 얼굴 지표

시드·방법	MAE	SSIM	LPIPS
42 일괄	0.136402	0.812108	0.101721
42 순차	0.137721	0.703040	0.132763
314 일괄	0.133931	0.831322	0.080904
314 순차	0.142639	0.731237	0.116147

표 6. 피부 영역·위치 보정 민감도

설정·방법	얼굴 LPIPS	피부 MAE	피부 SSIM	피부 고주파 MAE	피부 잔차 MAE
고정·일괄	0.091313	0.063146	0.789313	0.011295	0.027721
고정·순차	0.124455	0.062319	0.668437	0.015116	0.039894
$\sigma=0.5$ ·일괄	0.091313	0.063146	0.789313	0.011295	0.027721
$\sigma=0.5$ ·순차	0.123278	0.063252	0.660936	0.015450	0.039787
$\sigma=1.5$ ·일괄	0.091313	0.063146	0.789313	0.011295	0.027721
$\sigma=1.5$ ·순차	0.123278	0.063252	0.660936	0.015450	0.039787
$\sigma=3$ ·일괄	0.095030	0.064985	0.763278	0.012218	0.027467
$\sigma=3$ ·순차	0.126023	0.060812	0.654603	0.015549	0.038189

표는 두 시드의 평균이다. 얼굴 LPIPS와 SSIM, 피부 SSIM·고주파 MAE·잔차 MAE의 평균 방향은 모든 설정에서 일괄에 유리했다. 반면 피부 원시 MAE는 고정과 $\sigma=3$ 에서 순차가 더 낮았고, $\sigma=0.5$ 및 1.5에서는 두 방법이 매우 가까웠다. 시드 42의 피부 MAE는 모든 설정에서 순차가 더 낮았다. 따라서 “모든 얼굴·피부 지표에서 일괄이 우수하다”는 해석은 성립하지 않는다. 피부의 색 차이와 세부 구조 차이를 함께 보고해야 한다.

V. 시스템 설계로의 적용

관찰 결과를 바탕으로 최초 원본과 누적 편집 상태를 별도로 저장하는 로컬 편집기를 구현하였다. 사용자의 새 요청은 현재 상태에 대한 변경으로 해석하고, 생성 시에는 최초 원본과 갱신된 전체 요구를 사용한

시드·방법	MAE	SSIM	LPIPS
일괄 평균	0.135166	0.821715	0.091313
순차 평균	0.140180	0.717138	0.124455

평균 LPIPS는 일괄이 순차보다 26.6% 낮았다. 경로 전체 시간 평균은 약 92.8초와 261.2초였다. 일괄은 한 호출, 순차는 세 호출이므로 이 시간 차이는 품질 개선 알고리즘의 계산 효율만을 측정한 결과가 아니다. 한 인물과 두 시드의 제한된 재현 사례이며 기존 생성기의 숫자와 합쳐 평균을 계산하지 않는다.

5. 추가 사후 분석: 영역과 위치 보정

로컬 얼굴 ROI는 [176,44,336,224]이며 피부 영역은 이마 [226,72,284,89], 화면 왼쪽 볼 [206,132,224,153], 오른쪽 볼 [286,132,302,153]이다. 피부 좌표는 기존 고해상도 P04 영역의 정확한 절반이다. NCC 탐색 범위는 ± 32 픽셀로 설정했다. 원본 대조, 알려진 평행이동 회복, 기존 고정 얼굴 수치 재현 및 MSE 분해 항등식을 검증했으며 탐색 경계에 닿은 사례는 없었다.

다. 예를 들어 셔츠 변경 다음에 배경 변경을 요청하면 두 요구를 함께 적용하여 최초 원본에서 다시 생성한다. 이전 출력은 결과 이력에 저장하되 다음 이미지의 입력으로 사용하지 않는다.

현재 지원 범위는 셔츠 색, 배경, 원형 핀이다. 상태와 이미지 버전을 함께 보존하여 되돌리기를 지원한다. 요청 해석은 정해진 동작 처리와 Qwen3 4B의 구조화 출력 보조로 구성하고, 모호한 취소·이전 시점 요청은 상태를 임의 변경하지 않고 버전을 선택하도록 한다. 이미지 모델과 언어 모델은 메모리 부담을 줄이기 위해 동시에 실행하지 않는다.

한국어·영어 요청 35개와 연속 요청에 대한 검증은 개발 회귀 검사다. 이를 일반 자연어 이해 정확도나 전적으로 언어 모델이 해결한 성공률로 보고하지 않는다. 또한 이 구조는 누적 이미지 입력의 영향을 줄일 수

있지만 얼굴의 픽셀 보존, 임의 표현의 정확한 이해, 모든 중간 요구 이행을 보장하지 않는다. 시스템은 연구 가설의 적용 사례이며 새로운 기억 알고리즘이나 검증된 제품 효과의 증거가 아니다.

VI. 논의와 한계

첫째, 원본 기반 생성은 본 조건에서 얼굴 원본 거리와 사람의 보존 판정에 유리했다. 무변경 반복에서도 거리가 증가했다는 점을 함께 보면, 연속 요구를 기억하는 텍스트 상태와 생성 이미지의 입력 연결을 분리하는 설계는 합리적이다. 다만 복잡한 공간 관계나 직전 출력의 우연한 세부 유지해야 하는 작업에서는 최초 원본만으로 그 요구를 충분히 표현하지 못할 수 있다. 이 연구는 그러한 작업을 비교하지 않았다.

둘째, 측정 영역과 지표의 선택은 결론의 범위를 바꾼다. 얼굴 사각형의 거리, 피부 평균 색, 세부 고주파 성분, 사람이 본 열화는 서로 다른 측면이다. 새 피부 MAE의 반대 결과를 제외하고 얼굴 LPIPS만 제시하면 보존 효과를 과장할 수 있다. 반대로 색 차이가 작다는 이유로 순차 결과의 피부 구조가 더 잘 유지되었다고 단정하는 것도 적절하지 않다.

셋째, 평가자는 한 명이며 연구 결과에 노출되었다. 후속 재평가 역시 피드백 이후 수행되었다. 사람 결과는 예비 판단으로만 해석해야 한다. AI 입력 분리는 사람 결과를 직접 따라 매기는 위험을 줄이지만 AI의 독립적인 타당성을 확립하지 않는다. 같은 기반 모델의 두 세션 일치율이 높아도 편향을 공유할 수 있다.

넷째, 데이터는 합성 인물 6명과 제한된 비얼굴 과제에 집중되어 있다. 후속 반복은 주로 3명, 로컬 비교는 1명이다. 98개 출력이 98명의 독립 인물을 의미하지 않는다. 피부 유형·자세·표정·조명·해상도 및 실제 사용자 사진에 대한 일반화는 확인하지 않았다. 이미지 생성기의 버전 불확실성, 정책 간 공유 출력, 서로 다른 호출 예산도 해석을 제한한다.

다섯째, 로컬 민감도 분석은 결과를 본 뒤 수행했다. 여러 설정의 전체 보고와 재계산 검증은 선택적 보고를 줄이지만 사전 등록을 대신하지 못한다. 후속 검증 실험에서는 가설·ROI·주 지표·허용 실패·시드·제외 기준을 미리 고정하고, 새 인물과 새 요청을 사용해야 한다. 사람 평가에서는 결과를 보지 않은 복수 평가자가 무작위 익명 비교를 수행하고, 열화·보존·요청 이행을 별도로 판정해야 한다. 통계 분석은 인물 및 반복의 군집 구조를 반영해야 한다.

VII. 결론

본 탐색적 연구에서는 비얼굴 편집을 순차 수행할 때 최초 원본과의 얼굴 차이가 누적되는 사례를 관찰하였고, 원본 기반 또는 일괄 생성이 여러 비교에서 더 작은 얼굴 거리와 더 높은 예비 보존 판정을 보였다. 그러나 사람과 AI의 절대 열화 등급은 충분히 일치하지

않았으며, 추가 피부 내부 분석에서는 원시 MAE의 우열이 역전되었다. 실용적으로는 최초 원본과 누적 요구사항을 함께 관리하는 구조가 유망하지만, 연구적으로는 거리 감소·피부 열화 감소·얼굴 보존·요청 이행을 구별하는 평가가 필요하다. 본 결과는 보편적인 우월성이나 자동 열화 감지기의 검증보다 후속 검증 실험의 근거를 제공한다.

참고문헌

- [1] K. Zhang, L. Mo, W. Chen, H. Sun, and Y. Su. MagicBrush: A Manually Annotated Dataset for Instruction-Guided Image Editing. NeurIPS, 2023. <https://arxiv.org/abs/2306.10012>
- [2] Z. Zhou, Y. Deng, X. He, W. Dong, and F. Tang. Multi-turn Consistent Image Editing. arXiv:2505.04320, 2025. <https://arxiv.org/abs/2505.04320>
- [3] T. Chen et al. EdiVal-Agent: An Object-Centric Framework for Automated, Fine-Grained Evaluation of Multi-Turn Editing. arXiv:2509.13399, version 3, 2026. <https://arxiv.org/abs/2509.13399>
- [4] Y. Qian et al. GIE-Bench: Towards Grounded Evaluation for Text-Guided Image Editing. arXiv:2505.11493, 2025. <https://arxiv.org/abs/2505.11493>
- [5] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli. Image Quality Assessment: From Error Visibility to Structural Similarity. IEEE Transactions on Image Processing, 13(4), 600–612, 2004. <https://doi.org/10.1109/TIP.2003.819861>
- [6] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric. CVPR, 2018. <https://arxiv.org/abs/1801.03924>
- [7] Black Forest Labs. FLUX.2-klein-4B Model Card. 2026. Accessed 2026-09-10. <https://huggingface.co/black-forest-labs/FLUX.2-klein-4B>
- [8] MFLUX Community. MFLUX: FLUX.2 Implementation and Documentation. Software version used: 0.19.1. <https://github.com/mflux-community/mflux>